

学士論文

特許文書の課題・解決手段分離に基づく

クロウドメイン技術候補抽出

Cross-Domain Technology Candidate Extraction Based on Separating
Problems and Solutions in Patent Documents

大規模ネットワークサイエンス研究室

鳥井 春風

指導教員 大知 正直 准教授

2027 年 2 月

大分大学 理工学部 理工学科 知能情報システムコース

要 旨

本研究は、特許文書を用いたクロスドメイン技術候補抽出において、全文類似だけでは候補抽出理由を説明しにくいという問題に着目する。特許文書には、技術課題、解決手段、対象物、効果などが含まれるが、全文ベクトルとして一括で扱うと、どの観点で候補が近いのかが不明瞭になりやすい。そこで本研究では、特許文書を課題文脈である `problem_context` と解決手段文脈である `solution_context` に分離し、課題が近い異分野間において、対象分野では低出現または未使用である技術手法・解決手段を専門家確認候補として抽出する枠組みを検討した。実験 1 では、U-Net を対象とした近接解決策型の主分析を行い、医療画像解析分野で先行して現れた U-Net を、製造欠陥検出分野での後年出現を参照しながら後ろ向き評価した。その結果、U-Net は過去期間の具体的手法ランキングで 2 位となり、上位の専門家確認候補として確認された。実験 2 では、洗浄・除去系技術から半導体洗浄への異質解決策型の補助分析を行った。46 件のユニークファミリーを LLM 支援付き著者確認評価により確認した結果、◎ 11 件、○ 5 件、△ 12 件、× 18 件となった。ノイズも含まれた一方で、一部クラスターでは専門家確認候補として解釈可能な候補が得られた。また、軽量全文テキストベースラインとの比較により、提案手法と全文テキストベースラインの候補集合に差分があることを補助的に確認した。ただし、本研究は技術導入可能性を証明するものではなく、専門家確認候補を絞り込むスクリーニング手法として位置づける。

キーワード 特許文書, 課題・解決手段分離, クロスドメイン, 技術候補抽出, LLM

目次

第 1 章	序論	1
1.1	本章の概要	1
1.2	研究背景	2
1.3	問題意識	3
1.4	研究目的	4
1.5	本研究の対象範囲	5
1.6	本研究の貢献	5
1.7	本論文の構成	7
第 2 章	関連研究	9
2.1	本章の概要	9
2.2	特許文書を用いた技術分析	9
2.3	特許文書埋め込みと類似度分析	10
2.4	技術機会分析・類推型特許マイニング	12
2.5	技術拡散・時間差分析	13
2.6	LLM を用いた技術文書の構造化	14
2.7	本研究の位置づけ	15
第 3 章	提案手法	17
3.1	本章の概要	17
3.2	手法の全体像	18
3.3	特許文書の前処理	18
3.4	文脈抽出	19
3.5	ベクトル化と類似度計算	20
3.6	候補ランキング	21
3.7	候補タイプの定義	22
3.8	本手法の位置づけ	23
第 4 章	データセットと実験設計	25
4.1	本章の概要	25
4.2	使用データセットの全体像	25
4.3	実験 1 のデータセットと設計	26
4.4	実験 2 のデータセットと設計	28
4.5	ベースライン比較の設計	29
4.6	評価方法	29
4.7	実験設計上の注意	30
第 5 章	実験 1：U-Net を対象とした近接解決策型候補抽出	32

5.1	本章の概要	32
5.2	実験 1 の目的	33
5.3	データセットと期間設定	33
5.4	U-Net の出現傾向	34
5.5	候補抽出結果	35
5.6	ベースライン比較	37
5.7	LLM 支援付き著者確認評価	38
5.8	実験 1 のまとめ	39
第 6 章	実験 2：洗浄・除去系技術を対象とした異質解決策型補助分析	41
6.1	本章の概要	41
6.2	実験 2 の目的	42
6.3	S1 用途クラスターの構成	43
6.4	C1 候補母集団の作成	44
6.5	クラスター別候補ランキング	44
6.6	LLM 支援付き著者確認評価	45
6.7	軽量全文テキストベースラインとの補助比較	48
6.8	実験 2 のまとめ	50
第 7 章	考察	52
7.1	本章の概要	52
7.2	実験 1 から得られた示唆	52
7.3	実験 2 から得られた示唆	53
7.4	課題・解決手段分離の有効性	54
7.5	全文類似との違い	55
7.6	スクリーニング手法としての意義	56
7.7	本研究の限界	57
7.8	今後の展望	58
第 8 章	結論	59
8.1	本章の概要	59
8.2	本研究のまとめ	59
8.3	得られた示唆	60
8.4	本研究の限界	61
8.5	今後の課題	62
第 9 章	参考：クロスドメイン技術候補抽出研究の図表	64
9.1	候補タイプの定義と実験の位置づけ	64
9.2	提案手法の処理フロー	64
9.3	実験 1：U-Net 候補抽出フロー	64
9.4	実験 2：異質解決策型分析フロー	66
9.5	実験 1 の U-Net 候補抽出結果	66
9.6	実験 2 の異質解決策型分析	66
付録 A	LLM 文脈抽出プロンプトの概要	68
A.1	入力	68

A.2 抽出項目	68
A.3 利用上の注意	69
参考文献	70

目 次

1.1	本研究の全体像。特許文書を課題文脈と解決手段文脈に分離し、専門家確認候補を抽出するスクリーニング手法として整理する。	1
3.1	提案手法の処理フロー。特許文書の前処理、文脈抽出、ベクトル化、候補ランキング、LLM 支援付き著者確認評価までを示す。	17
3.2	課題文脈類似度と解決手段文脈類似度に基づく候補タイプの概念図。実験 1 を主分析、実験 2 を補助分析として位置づける。	22
5.1	実験 1 の処理フロー。U-Net を対象とした近接解決策型候補抽出を主分析として扱う。	32
5.2	U-Net の年次出現傾向。医療画像解析分野と製造欠陥検出分野における出現時期の違いを後ろ向き評価の前提として示す。	34
5.3	実験 1 における提案手法と全文類似上位ベースラインの比較。単純な優劣ではなく、候補集合の性質差を確認する補助比較として扱う。	37
6.1	実験 2 の処理フロー。S1 用途クラスタ、C1 非半導体系 pre 候補、各クラスタ上位 20 件、7 クラスタ分、ファミリー単位の重複統合、46 件の LLM 支援付き著者確認評価を示す。	41
6.2	実験 2 における評価ラベルの分布。46 件のユニークファミリーを対象にした LLM 支援付き著者確認評価の結果を示す。	46
6.3	実験 2 におけるクラスタ別評価ラベル分布。クラスタ依存性を確認するための補助図である。	46
6.4	提案手法と軽量全文テキストベースラインの候補集合の重複・差分。精度優劣ではなく候補集合の傾向差を確認する。	49
9.1	候補タイプと実験の位置づけ	65
9.2	提案手法の全体処理フロー	65
9.3	実験 1 フロー：U-Net を対象とした近接解決策型	65
9.4	実験 2 フロー：異質解決策型の補助分析	66

表 目 次

3.1	LLM により抽出する文脈項目の定義	19
3.2	近接解決策型と異質解決策型の定義	22
4.1	本研究で用いた主要データセットの概要	26
4.2	実験 1 におけるデータセットと期間分割	27
5.1	実験 1 における U-Net 出現状況	35
5.2	U-Net 候補抽出に関する後ろ向き確認結果	36
5.3	実験 1 における提案手法と全文類似上位ベースラインの比較	37
6.1	実験 2 における LLM 支援付き著者確認評価の全体集計	47
6.2	実験 2 におけるクラスター別評価集計	47
6.3	実験 2 における提案手法と軽量全文テキストベースラインの比較	48
7.1	実験 1 と実験 2 の位置づけの比較	52
7.2	本研究の限界	57

第1章 序論

1.1 本章の概要

本章では、本研究の背景、問題意識、研究目的、対象範囲、貢献、および本論文の構成を述べる。本研究のテーマは、特許文書の課題・解決手段分離に基づくクロスドメイン技術候補抽出である。

特許文書には、発明が解決しようとする技術課題、具体的な解決手段、対象物、効果などが記述されている。そのため、特許文書は技術動向を把握するためだけでなく、異なる分野に存在する技術手法や解決手段を探索するための知識源としても利用できる。

一方で、異分野間の技術候補探索では、単なるキーワード一致や全文類似だけでは、候補が提示された理由を説明しにくい場合がある。全文類似では、課題、対象物、解決手段、効果が一つの表現に混在するため、ど




図 1.1: 本研究の全体像。特許文書を課題文脈と解決手段文脈に分離し、専門家確認候補を抽出するスクリーニング手法として整理する。

の観点で候補が近いのかを判断しにくいからである。

そこで本研究では、特許文書を `problem_context` と `solution_context` に分離し、課題が近い異分野間において、対象分野では低出現または未使用である技術手法・解決手段を、専門家が確認すべき候補として抽出する枠組みを検討する。本研究は、技術導入可能性を証明するものではなく、専門家確認候補を絞り込むためのスクリーニング手法として位置づける。

1.2 研究背景

本節では、本研究の背景として、特許文書を用いた技術候補探索の意義を述べる。

企業や研究機関が新しい技術開発の方向性を検討する際、自分たちの分野内だけでなく、他分野で用いられている技術手法や解決手段を参照することが重要になる場合がある。ある分野で発展した技術が、別の分野の類似した課題に対して参考になる可能性があるためである。たとえば、画像解析、材料処理、洗浄、検査、制御などの技術は、対象物や用途が異なっているにもかかわらず、共通する課題を含むことがある。

このような異分野間の技術候補探索において、特許文書は有用な情報源である。特許文書には、技術の名称だけでなく、その技術が何を目的としているのか、どのような課題を解決しようとしているのか、どのような手段を用いているのか、どのような効果が期待されるのかが記述されている。したがって、特許文書を分析することで、単なる技術語の出現頻度だけではなく、課題と解決手段の関係を読み取ることができる。

近年では、自然言語処理技術や文書埋め込み技術の発展により、大量の特許文書をベクトル化し、類似度に基づいて検索・ランキングすることが可能になっている。これにより、従来よりも広い範囲から類似特許や関連技術を探索できるようになった。

しかし、特許文書は長く、複数の情報が混在している。発明の課題、対

象物、構成、作用効果、請求項の限定表現が一つの文書に含まれるため、文書全体を一つのベクトルとして扱った場合、どの情報が類似度に強く影響したのかを説明しにくい。この点は、異分野間の候補探索において特に問題となる。

1.3 問題意識

本節では、本研究が対象とする問題意識を整理する。

異分野間の技術候補探索では、対象分野と参照分野で使われる語彙や対象物が異なることが多い。そのため、キーワード一致だけでは、同じような課題に取り組んでいる候補を見落とす可能性がある。一方で、全文類似を用いる場合でも、特許文書全体の類似度が高い理由が、課題の近さによるものなのか、対象物の一致によるものなのか、解決手段の類似によるものなのかを区別しにくい。

たとえば、ある候補特許が対象分野の特許と全文として似ていたとしても、その類似が対象物の名称に由来するだけであれば、異分野から新しい解決手段を探す目的には十分でない場合がある。逆に、対象物や用途名は異なっているにもかかわらず、解いている課題が近く、解決手段が参考になる候補は、全文類似だけでは上位に現れにくい可能性がある。

この問題は、候補抽出結果を人間が確認する段階でも重要である。候補が提示されたとき、評価者や専門家は「なぜこの候補を見るべきなのか」を理解する必要がある。全文類似に基づくランキングでは、候補抽出理由を説明する際に、課題、対象物、解決手段、効果が混在しやすい。そのため、専門家確認候補として提示するには、候補の根拠をより解釈しやすい形で整理する必要がある。

本研究では、この問題意識に基づき、特許文書を全文ベクトルとして一括で扱うのではなく、課題文脈と解決手段文脈に分離して扱う。具体的には、`problem_context` を「何の課題を解いているか」を表す文脈、`solution_context` を「どのように解いているか」を表す文脈として定義する。この分離により、課題が近い異分野間において、対象分野では低

出現または未使用である技術手法・解決手段を候補として抽出し、その理由を説明しやすくすることを目指す。

1.4 研究目的

本節では、本研究の目的を述べる。

本研究の目的は、特許文書を課題文脈と解決手段文脈に分離し、課題が近い異分野間において、対象分野では低出現または未使用である技術手法・解決手段を、専門家確認候補として抽出する枠組みを検討することである。

本研究では、特許文書の Title、Abstract、Claims を中心に用い、LLM を用いて `problem_context`、`solution_context`、`technical_means`、`target_object`、`application_field`、`effect_context` などの項目を抽出する。ただし、LLM は候補の妥当性を最終判定するものではない。本研究における LLM の役割は、長く複雑な特許文書を、人間が確認しやすい文脈単位に整理する支援である。

抽出された文脈を用いて、参照分野と対象分野の間で課題の近さを確認し、対象分野ではまだ低出現または未使用である技術手法・解決手段を候補としてランキングする。候補は、技術導入可能性が確認されたものとしてではなく、専門家が確認すべき候補として扱う。

本研究では、この枠組みを二つの実験で確認する。実験1では、U-Net を対象とした近接解決策型の候補抽出を扱う。医療画像解析分野を参照分野、製造欠陥検出分野を対象分野とし、医療画像解析分野で先行して現れたU-Net関連技術が、製造欠陥検出分野で後年確認されるという設定を用いて、後ろ向き評価を行う。実験1は、本卒論の主分析である。

実験2では、洗浄・除去系技術から半導体洗浄に接続しうる異質解決策型の候補抽出を扱う。花王の洗浄・除去系技術を含む候補集合から、半導体洗浄に関連する既知事例の用途クラスタに対して、非半導体系の先行候補をランキングする。実験2は、本卒論の補助分析であり、技術導入可能性や企業進出を予測するものではない。

1.5 本研究の対象範囲

本節では、本研究で扱う範囲と扱わない範囲を明確にする。

本研究が扱う対象は、特許文書に記述された技術課題、解決手段、対象物、効果などの情報を用いた、クロスドメイン技術候補の抽出である。ここでいう候補とは、対象分野において専門家が確認すべき技術手法・解決手段の候補であり、実際に導入可能であることが確認された技術ではない。

本研究は、特許文書に基づくスクリーニング手法を扱う。そのため、実験結果は、候補の解釈可能性や確認対象としての妥当性を検討するものであり、技術導入可能性の証明ではない。また、将来の技術導入を予測することも目的としない。特許文書は技術知識源として有用である一方で、特許が存在することは、その技術が製品化されたことや実装されたことを直接意味しないためである。

評価については、LLM支援付き著者確認評価として扱う。これは、LLMによって整理された文脈情報をもとに、著者が候補を確認する評価である。したがって、本研究の評価は、完全な第三者専門家評価ではない。この点は、本研究の限界として明示する。

また、本研究では、近接解決策型と異質解決策型という二つの候補タイプを扱う。近接解決策型は、参照分野と対象分野の課題や技術的背景が比較的近く、ある分野で先行して現れた手法が別分野でも後年確認されるような候補を想定する。異質解決策型は、対象物や用途は異なるが、課題や効果の観点から専門家確認候補として読みうる技術を想定する。実験1は近接解決策型の主分析、実験2は異質解決策型の補助分析として位置づける。

1.6 本研究の貢献

本節では、本研究の貢献を整理する。

第一の貢献は、特許文書を `problem_context` と `solution_context` に分離

し、課題文脈と解決手段文脈に基づいてクロスドメイン技術候補を抽出する枠組みを示した点である。全文類似では、課題、対象物、解決手段、効果が混在しやすい。これに対して、本研究では、何の課題が近いのか、どの解決手段が候補なのかを分けて扱うことで、候補抽出理由を説明しやすくする。

第二の貢献は、U-Net を対象とした近接解決策型の主分析を行った点である。医療画像解析分野で先行して現れた U-Net 関連技術を参照し、製造欠陥検出分野における後年出現を用いた後ろ向き評価を行うことで、専門家確認候補を抽出する枠組みを検討した。ただし、この実験は医療画像解析から製造欠陥検出への技術移転を証明するものではない。

第三の貢献は、洗浄・除去系技術から半導体洗浄に接続しうる異質解決策型の補助分析を行った点である。実験 2 では、既知事例を用途クラスタに整理し、非半導体系の先行候補をランキングしたうえで、LLM 支援付き著者確認評価により候補の解釈可能性を確認した。この分析は、技術導入可能性や企業進出を示すものではなく、異質な分野間でも専門家確認候補を抽出できる可能性を補助的に確認するものである。

第四の貢献は、候補の良し悪しを自動的に断定するのではなく、人間が確認すべき情報を整理する評価用データ作成と評価設計を行った点である。本研究では、ランキングスコアだけで候補の価値を判断するのではなく、抽出された課題文脈、解決手段文脈、技術手段、対象物、効果などを確認できる形で評価ファイルを作成し、LLM 支援付き著者確認評価を行った。

以上の貢献により、本研究は、特許文書を用いた異分野技術候補探索において、全文類似とは異なる観点から、説明しやすい専門家確認候補を抽出するスクリーニング手法を検討する。

1.7 本論文の構成

本節では、本論文の構成を述べる。

第1章では、本研究の背景、問題意識、研究目的、対象範囲、貢献、および論文構成を述べた。特許文書を用いた異分野技術候補抽出において、全文類似だけでは候補抽出理由を説明しにくいという問題意識を示し、本研究を専門家確認候補を絞り込むスクリーニング手法として位置づけた。

第2章では、本研究に関連する研究を整理する。具体的には、特許文書を用いた技術分析、特許文書埋め込みと類似度分析、技術機会分析、類推型特許マイニング、技術拡散・時間差分析、LLMを用いた技術文書の構造化に関する研究を概観し、本研究の位置づけを明確にする。

第3章では、提案手法を説明する。特許文書を Title、Abstract、Claims を中心に前処理し、LLM によって `problem_context`、`solution_context`、`technical_means` などを抽出したうえで、課題文脈と解決手段文脈に基づいて候補をランキングする流れを述べる。また、近接解決策型と異質解決策型の定義を示す。

第4章では、データセットと実験設計を説明する。実験1で用いる A0/A1/B0/B1、実験2で用いる S1、C1、S0_pre、S0_pre_filteredなどのデータセット、期間分割、ベースライン比較、評価方法を整理する。

第5章では、実験1として、U-Netを対象とした近接解決策型の候補抽出を検証する。医療画像解析分野と製造欠陥検出分野を対象に、U-Netの出現傾向、候補抽出結果、ベースライン比較、LLM支援付き著者確認評価を示す。実験1は本卒論の主分析である。

第6章では、実験2として、洗浄・除去系技術を対象とした異質解決策型の補助分析を行う。S1用途クラスタ、C1候補母集団、クラスタ別ランキング、LLM支援付き著者確認評価、軽量全文テキストベースラインとの補助比較を示す。実験2は補助分析であり、技術導入可能性や企業進出を示すものではない。

第7章では、実験1と実験2の結果を統合して考察する。課題文脈・解

決手段文脈の分離に基づく候補抽出の有効性、全文類似との違い、スクリーニング手法としての意義、限界、今後の課題を整理する。

以上の構成により、本論文では、特許文書を全文ベクトルとして一括で扱うのではなく、課題文脈と解決手段文脈に分離することで、異分野間の専門家確認候補を説明しやすく抽出する枠組みを検討する。

第2章 関連研究

2.1 本章の概要

本章では、本研究に関連する研究領域を整理し、本研究の位置づけを明確にする。対象とする関連研究は、特許文書を用いた技術分析、特許文書埋め込みと類似度分析、技術機会分析、類推型特許マイニング、技術拡散・時間差分析、LLMによる技術文書の構造化である。

本研究は、特許文書を用いた技術候補探索という点で、既存の特許分析研究や文書埋め込み研究と関係する。一方で、本研究の特徴は、特許文書を全文ベクトルとして一括で扱うのではなく、`problem_context`と`solution_context`に分離して扱う点にある。これにより、課題が近い異分野間において、対象分野では低出現または未使用である技術手法・解決手段を、専門家確認候補として抽出することを目指す。

本章では、既存研究を本研究の比較対象として否定するのではなく、既存研究が提供してきた知見を整理したうえで、本研究がどの点を補完するのかを述べる。

2.2 特許文書を用いた技術分析

本節では、特許文書を技術分析に用いる研究を概観する。特許文書は、発明の技術内容、課題、解決手段、出願人、時系列、引用関係、分類情報を含むため、技術動向や競争環境を分析するための重要なデータ源として用いられてきた。

特許分析では、特許分類、引用関係、出願件数、出願人、キーワード、技術語の共起などを用いて、技術領域の構造や変化を把握する研究が多く行われている。特許統計を経済指標として用いる基礎研究とし

ては、Griliches (1990) や OECD Patent Statistics Manual (OECD, 2009) があり、特許引用と技術価値の関係については Trajtenberg (1990)、Jaffe, Trajtenberg, and Henderson (1993)、Hall, Jaffe, and Trajtenberg (2005) などの研究がある。たとえば、特許分類を用いることで、技術分野ごとの出願動向を整理できる。また、引用関係を用いることで、ある発明がどの先行技術に依拠しているか、あるいは後続技術からどの程度参照されているかを分析できる。

一方で、特許データを用いる際には注意も必要である。特許は発明を保護するための制度的文書であり、特許が存在することは、その技術が実際に実装されたことや製品化されたことを直接意味しない。また、戦略的出願や防衛的出願のように、特許が必ずしも実際の技術利用と一対一に対応しない場合もある。Strategic Patentingに関する研究では、Noel and Schankerman (2013) などが、特許が技術情報であると同時に、競争上のポジションを形成する戦略的手段でもあることを指摘している。

また、Patents to Productsに関する研究では、特許と製品イノベーション、企業動態との関係を扱う重要性が示されている (Argente et al., 2025)。一方で、特許文書のみから製品化や実装状況を直接判断することは難しい。したがって、本研究でも、特許文書から抽出された候補を、技術導入可能性が確認されたものとして扱うのではなく、専門家が確認すべき候補として位置づける。

以上のように、特許文書は技術分析の有用なデータ源であるが、特許が実装や製品化を保証するわけではない。本研究は、この限界を踏まえ、特許文書を専門家確認候補のスクリーニングに用いる。

2.3 特許文書埋め込みと類似度分析

本節では、特許文書の埋め込み表現と類似度分析に関する研究を整理する。近年、自然言語処理の発展により、特許文書をベクトル表現に変換し、意味的類似度を計算する手法が広く用いられている。

一般的な文埋め込みの基盤として、BERT (Devlin et al., 2019) がある。

BERT は Transformer (Vaswani et al., 2017) に基づく双方向言語モデルであり、その後の文書分類や検索、類似度計算の基盤となった。Sentence-BERT は、BERT を Siamese network や triplet network の構造で用いることで、文や短いテキストの意味的類似度を効率的に計算できるようにした手法である (Reimers and Gurevych, 2019)。また、RoBERTa (Liu et al., 2019) のような事前学習モデルの改良も、文書埋め込み研究の基盤となっている。

特許文書に特化した言語モデルとしては、PatentBERT (Lee and Hsiang, 2020) や PatentSBERTa が挙げられる。PatentBERT は、事前学習済み BERT を特許分類にファインチューニングすることで、特許テキストの分類性能を高めることを目的とした研究である。PatentSBERTa は、SBERT を特許テキスト、とくに claims に適用し、patent-to-patent technological similarity を計算する枠組みを提案している (Bekamiri, Hain, and Jurowetzki, 2024)。このような研究は、特許間の技術的近さを大規模に計算し、類似特許検索や自動分類、技術ランドスケープ分析に利用できる点で有用である。

また、patent-to-patent technological similarity に関する研究では、特許テキストの類似度を用いて、技術的距離、技術領域の変化、イノベーションの流れを分析する試みが行われている。たとえば、Hain らは、特許テキスト埋め込みを用いて特許間の技術的類似度を測定する方法を提案している (Hain et al., 2022)。このような研究により、個別特許間の近さだけでなく、技術領域全体の構造や変化を捉える分析が可能になる。

これらの研究は、特許文書全体または claims などの特定テキストをベクトル化し、類似度を計算する点で本研究と関係する。しかし、全文または claims 全体をまとめて埋め込む場合、課題、対象物、解決手段、効果が同じ表現に混在する。そのため、候補が抽出された理由を「課題が近いからなのか」「対象物が似ているからなのか」「解決手段が似ているからなのか」に分けて説明しにくい。

本研究は、特許文書埋め込み研究を否定するものではない。むしろ、文書埋め込みによる大規模検索の有用性を踏まえたうえで、候補抽出理由を説明しやすくするために、特許文書を `problem_context` と `solution_context` に分離する点に特徴がある。

2.4 技術機会分析・類推型特許マイニング

本節では、技術機会分析と類推型特許マイニングに関する研究を整理する。技術機会分析は、既存技術や市場、特許情報を用いて、新たな技術開発の方向性や応用可能な技術領域を探索する研究領域である。

特許を用いた technology opportunity analysis では、特許分類、技術語、引用、出願人、時系列情報などを組み合わせて、まだ十分に活用されていない技術機会を探索する。たとえば、Han et al. (2021) はSAOネットワークとリンク予測を組み合わせた技術機会分析を提案している。近年では、BERTなどの文書埋め込みとTRIZを組み合わせ、技術課題や矛盾、解決原理を抽出する研究も行われている。Wang et al. (2023) は、BERTとTRIZを用いて技術要素を拡張し、技術機会分析に接続する枠組みを示している。TRIZは、特許に現れる発明原理や技術的矛盾を整理し、異分野の解決原理を探索するための方法論として知られている。

類推型特許マイニングに関する研究では、異なる分野に存在する類似課題や類似機構を見つけ、発想支援や技術探索に活用することが試みられている。Jeong and Kim (2014) は、類推に基づく特許マイニングを用いて新技術に関する特許創出を支援する枠組みを提案している。また、Hopeらのanalogy mining研究では、目的や機構といった構造的表現を用いて、単純な情報検索では見つけにくい類推候補を探索することの有効性が示されている (Hope et al., 2017)。

また、cross-cutting patent analysisでは、複数の技術領域を横断する特許や、複数分野にまたがる技術要素を分析することで、分野間の接続や技術的橋渡しを捉えようとする。Liu et al. (2023) は、cross-cutting patent analysisとリンク予測を用いて、技術機会からアイデア生成へ接続する方法を検討している。これらの研究は、本研究が扱うクロスドメイン技術候補抽出と問題意識を共有している。

一方で、既存の技術機会分析や類推型特許マイニングでは、特許文書全体の類似度、分類、引用、キーワード、または抽象化された機能・原理に基づく分析が多い。本研究は、これらを補完するために、特許文書か

ら課題文脈と解決手段文脈を抽出し、課題に近い異分野間で、対象分野では低出現または未使用である技術手法・解決手段を専門家確認候補として抽出する。

この点で、本研究は、技術機会分析や類推型特許マイニングの問題意識を受け継ぎつつ、候補抽出理由を「課題」と「解決手段」に分けて説明しやすくすることを目指す。

2.5 技術拡散・時間差分析

本節では、技術拡散と時間差分析に関する研究を整理する。技術は、ある分野で先に現れた後、別の分野で応用されることがある。そのため、特許データを用いて、技術の出現時期や分野間の時間差を分析する研究が行われている。

技術拡散研究では、出願件数の推移、引用関係、特許分類の変化、企業や国・地域の出願動向を用いて、技術がどのように広がるかを分析する。特許データは時系列情報を含むため、ある技術語や技術手法が、どの分野で先に現れ、どの分野で後に現れたかを確認することができる。

一方で、時系列上の先後関係は、技術移転の因果関係を直接意味しない。ある技術語が一方の分野で先に出現し、別の分野で後に出現したとしても、それだけで技術が移転したとは言えない。技術拡散を厳密に論じるには、引用関係、研究開発主体、製品化、実験的検証、事業上の判断など、追加の情報が必要である。

本研究では、時間差を因果関係の証明として扱わない。実験1では、医療画像解析分野で先行して現れたU-Net関連技術が、製造欠陥検出分野で後年確認されるという設定を、後ろ向き評価の対象として用いる。これは、将来の技術導入を予測するためではなく、過去時点の情報から、後年に対象分野で確認される代表的手法を専門家確認候補として抽出できるかを確認するためである。

同様に、実験2における時系列条件も、既知の半導体洗浄事例より前

に存在する非半導体系候補を整理するために用いる。これは、候補の技術導入可能性を示すものではなく、専門家確認候補として読むべき候補集合を作成するための条件である。

2.6 LLM を用いた技術文書の構造化

本節では、LLMを用いた技術文書の抽出・構造化に関する研究を整理する。大規模言語モデルは、長い技術文書から要点を抽出し、課題、解決手段、効果、技術要素などを整理するために利用されつつある。

特許文書に対するLLM利用では、要約、キーフレーズ抽出、請求項の解釈支援、技術的矛盾の抽出、TRIZ概念との対応づけなどが研究されている。Giordano et al. (2023) は、特許文書から problem、solution、advantage を抽出し、発明過程を構造化する試みを行っている。この研究は、特許文書を単なる全文ではなく、発明の構成要素に分けて扱う点で、本研究の問題意識と近い。

また、LLMを用いて特許文書からTRIZ的な contradiction を抽出する研究では、特許の課題や矛盾を構造化する可能性が示されている (Trapp and Warschat, 2024)。

LLMを用いる利点は、長く複雑な特許文書から、人間が読みたい単位の情報を抽出できる点にある。特許文書は、Title、Abstract、Claims に多くの情報を含むが、文体が複雑であり、複数の言語や翻訳を含む場合もある。LLMは、このような文書から、課題、解決手段、対象物、効果を整理する支援として有用である。

一方で、LLMによる抽出結果は常に正しいとは限らない。誤抽出、過度な一般化、重要情報の欠落が起こる可能性がある。そのため、本研究では、LLM を候補の妥当性を最終的に判定する主体としては扱わない。LLMは、特許文書を problem_context、solution_context、technical_means などに整理する支援として用いる。最終的な候補確認は、LLM 支援付き著者確認評価として行う。

このように、本研究はLLMの抽出能力を活用しつつ、その結果を無批

判に正解として扱わない。LLMによる文脈整理と人手確認を組み合わせることで、専門家確認候補の抽出を支援する。

2.7 本研究の位置づけ

本節では、以上の関連研究を踏まえ、本研究の位置づけを整理する。既存研究では、特許文書全体の類似度、特許分類、引用、キーワード、文書埋め込みを用いた分析が多く行われてきた。これらの手法は、大規模な技術動向把握や類似特許検索に有用である。

一方で、全文類似では、課題、対象物、解決手段、効果が混ざるため、候補抽出理由を説明しにくい場合がある。特に、クロスドメイン技術候補抽出では、対象物や分野名が異なっているにもかかわらず、解こうとしている課題が近い候補を見つけない場合がある。この場合、全文として似ているかどうかだけでなく、「何の課題が近いのか」「どの解決手段が候補なのか」を分けて扱う必要がある。

本研究は、この点を補完するために、特許文書を `problem_context` と `solution_context` に分離する。`problem_context` は発明が解こうとしている課題を表し、`solution_context` はその課題に対してどのような解決手段を提示しているかを表す。さらに、`technical_means`、`target_object`、`application_field`、`effect_context`を抽出することで、候補の内容を人間が確認しやすい形に整理する。

本研究の目的は、技術導入可能性を証明することではない。また、将来の技術導入を予測することでもない。目的は、課題が近い異分野間において、対象分野では低出現または未使用である技術手法・解決手段を、専門家確認候補として抽出することである。

実験では、2種類の設定を扱う。実験1では、U-Netの医療画像解析から製造欠陥検出への近接解決策型候補抽出を主分析として扱う。実験2では、花王の洗浄・除去系技術から半導体洗浄への異質解決策型候補抽出を補助分析として扱う。これにより、比較的近い課題・解決手段を持つ設定と、対象物や工程が異なる設定の両方で、本手法の特徴を確認

する。

以上より、本研究は、特許文書埋め込み、技術機会分析、類推型特許マイニング、LLMによる技術文書構造化の研究を補完するものとして位置づけられる。特に、候補抽出理由を説明しやすくするために、課題文脈と解決手段文脈を分離し、専門家確認候補を抽出するスクリーニング手法として提案する点に特徴がある。

第3章 提案手法

3.1 本章の概要

本章では、本研究で用いるクロスドメイン技術候補抽出手法の全体像を説明する。本研究では、特許文書を単一の全文ベクトルとして扱うのではなく、課題文脈である `problem_context` と、解決手段文脈である `solution_context` に分離して扱う。これにより、課題に近い異分野間において、対象分野では低出現または未使用である技術手法・解決手段を、専門家が確認すべき候補として抽出することを目指す。

本手法は、技術導入可能性を直接示すものではない。あくまで、特許文書中の課題と解決手段を整理し、専門家が確認すべき候補を絞り込むためのスクリーニング手法として位置づける。

本章では、まず手法全体の流れを示し、次に特許文書の前処理、文脈抽出、ベクトル化、類似度計算、候補ランキングの方法を説明する。最後に、本研究で扱う近接解決策型と異質解決策型を定義し、実験1と実験2の位置づけを述べる。

提案手法の全体処理フロー



図 3.1: 提案手法の処理フロー。特許文書の前処理、文脈抽出、ベクトル化、候補ランキング、LLM 支援付き著者確認評価までを示す。

3.2 手法の全体像

本節では、提案手法の全体的な処理フローを説明する。提案手法は、特許文書の取得、文書単位の整理、LLMによる文脈抽出、文脈ベクトル化、候補ランキング、人手評価の手順から構成される。

入力となるデータは、主に特許文書の Title、Abstract、Claims である。これらのテキストには、発明が対象とする課題、解決手段、対象物、効果などが含まれる。しかし、全文をまとめてベクトル化すると、課題、対象物、解決手段、効果が同一の表現空間に混在しやすい。そのため、候補がなぜ抽出されたのかを説明しにくくなる。

そこで本研究では、特許文書を文脈単位に分解する。具体的には、発明が「何の課題を解いているか」を表す `problem_context` と、「どのように解いているか」を表す `solution_context` を分離する。さらに、具体的な技術手段や手法名を表す `technical_means`、対象物を表す `target_object`、適用分野を表す `application_field`、効果を表す `effect_context` を抽出する。

図 3.1 に、提案手法の全体処理フローを示す。まず特許文書を収集し、公開公報単位またはファミリー単位で整理する。次に、LLMを用いて文脈情報を抽出し、課題文脈と解決手段文脈を分けて扱う。その後、文脈ごとにベクトル化を行い、課題が近い異分野間の候補を抽出する。最終的に得られた候補は、専門家確認候補として人手評価の対象とする。

3.3 特許文書の前処理

本節では、候補抽出に用いる特許文書の前処理について説明する。特許文書は同一発明について複数の公開公報を持つことがあるため、公開公報単位だけでなく、ファミリー単位での整理が重要となる。

本研究では、Title、Abstract、Claims を中心にテキストを構成する。Title は発明の概要を短く示し、Abstract は発明の目的や構成を要約し、Claims は権利範囲として発明の構成を詳細に記述する。これらを組み合わせることで、課題と解決手段の両方を含むテキスト情報を得る。

表 3.1: LLM により抽出する文脈項目の定義

抽出項目	定義
problem_context	発明が解こうとする課題、目的、問題点
solution_context	課題に対して提示される構成、方法、処理手順
technical_means	具体的な技術手段、手法名、材料、構成要素
target_object	技術が適用される対象物や材料
application_field	発明が用いられる応用分野や利用場面
effect_context	発明によって得られる効果や改善点

また、時系列条件を扱うために、日付情報を整理する。優先日である `priority_date` が存在する場合はこれを優先し、存在しない場合は `filing_date` を用いる。これにより、同一ファミリー内で最も早い日付をファミリーの初出日として扱うことができる。時系列を整理することで、ある分野で先に現れた技術手法や解決手段が、対象分野で後に現れるかどうかを確認するための基礎を作る。

ただし、本研究で扱う時系列分析は、技術導入の因果関係を示すものではない。あくまで、過去時点で観測可能な特許文書から、後に対象分野で注目される可能性のある専門家確認候補を抽出できるかを検討するための条件設定である。

3.4 文脈抽出

本節では、LLMを用いた文脈抽出の方法と、抽出項目の意味を説明する。LLMは最終的な候補の妥当性を判定するためではなく、特許文書に含まれる情報を整理する支援として用いる。

本研究で抽出する主な項目は以下の通りである。

`problem_context` 発明が解こうとしている課題、目的、問題点を表す。すなわち「何の課題を解いているか」に対応する。

`solution_context` 課題に対して発明が提示する構成、方法、処理手順を表す。すなわち「どのように解いているか」に対応する。

`technical_means` 具体的な技術手段、手法名、材料、構成要素、処理方法を表す。

`target_object` 技術が適用される対象物を表す。

`application_field` 発明が用いられる応用分野や利用場面を表す。

`effect_context` 発明によって得られる効果や改善点を表す。

表3.1に、これらの抽出項目の定義を示す。特に重要なのは、`problem_context`と`solution_context`を分ける点である。全文類似では、例えば「医療画像」「欠陥検出」「半導体基板」「洗浄剤組成物」といった対象物や分野名が強く影響する。一方で、異分野技術探索では、対象物が異なっている場合でも、解こうとしている課題が近い場合がある。そのため、課題文脈と解決手段文脈を分離することで、候補抽出理由を説明しやすくする。

なお、LLMによる抽出には誤抽出や過度な一般化の可能性がある。そのため、抽出結果は候補ランキングのための中間表現として用い、最終的な評価は人手による確認を通じて行う。

なお、文脈抽出プロンプトの概要は付録Aに示す。

3.5 ベクトル化と類似度計算

本節では、抽出した文脈情報を用いたベクトル化と類似度計算について説明する。本研究では、全文をそのまま1つのベクトルとして扱うのではなく、抽出した文脈ごとにベクトル表現を作成する。

全文ベクトルを用いる方法では、課題、対象物、解決手段、効果などが同時に反映されるため、文書全体として似ている候補を得ることはできる。しかし、クロスドメイン技術探索では、文書全体が似ていることよりも、「課題が近いが、解決手段や対象分野が異なる」候補を見つけることが重要な場合がある。全文類似だけでは、このような候補の抽出理由を説明しにくい。

そこで本研究では、`problem_context`を用いて課題の近さを評価し、必要に応じて`solution_context`や`technical_means`を参照して候補の内容を確認する。これにより、候補が抽出された理由を「課題が近い」「解決手段

としてこの技術が使われている」という形で説明しやすくなる。

類似度計算では、対象となる分野間で文脈ベクトルを比較し、課題文脈が近い候補を抽出する。実験1では、医療画像解析分野と製造欠陥検出分野のように、画像認識・領域抽出という課題が比較的近い領域を扱う。実験2では、洗浄・除去という課題に着目しつつ、対象物や工程が異なる候補を扱う。

3.6 候補ランキング

本節では、候補ランキングの考え方を説明する。候補ランキングでは、課題文脈の近さに基づいて異分野間の候補を抽出し、対象分野では低出現または未使用である技術手法・解決手段を専門家確認候補として整理する。

候補抽出の基本的な考え方は、次の通りである。ある分野で用いられている解決手段が、別分野における近い課題に対して参考になる可能性がある場合、その解決手段を専門家が確認すべき候補として提示する。ここで重要なのは、候補を提示することであり、その技術が実際に導入可能であることを示すわけではない点である。

実験1では、U-Netを代表例として扱う。医療画像解析分野において用いられてきた画像セグメンテーション手法が、製造欠陥検出分野における画像ベースの検査課題に対して、専門家確認候補として抽出できるかを確認する。

実験2では、洗浄・除去系技術を対象とする。花王の非半導体領域における洗浄・除去系特許から、半導体洗浄課題に接続しうる候補を抽出する。ただし、これは半導体洗浄への実装や適用を示すものではなく、異質解決策型における候補の解釈可能性を補助的に確認する分析である。

候補ランキングの評価では、上位候補を手で確認し、◎ / ○ / △ / ×などのラベルを付与する。これにより、抽出された候補が専門家確認候補としてどの程度読み取れるかを確認する。




図 3.2: 課題文脈類似度と解決手段文脈類似度に基づく候補タイプの概念図。実験 1 を主分析、実験 2 を補助分析として位置づける。

表 3.2: 近接解決策型と異質解決策型の定義

候補タイプ	定義	対象実験	例	位置づけ
近接解決策型	課題文脈と解決手段文脈の双方が比較的近い候補	実験 1	U-Net	主分析
異質解決策型	課題文脈には関連があるが、対象物・材料・分野が大きく異なる候補	実験 2	洗浄・除去系技術	補助分析

3.7 候補タイプの定義

本節では、本研究で扱う2種類の候補タイプを定義する。図3.2に、課題文脈類似度と解決手段文脈類似度に基づく概念的な位置づけを示す。また、表3.2に各タイプの定義を示す。

第1のタイプは、近接解決策型である。これは、課題文脈と解決手段

文脈の両方が比較的近い異分野間の候補である。実験1では、医療画像解析から製造欠陥検出へのU-Net関連候補抽出を近接解決策型として扱う。医療画像解析と製造欠陥検出は対象分野は異なるが、画像から対象領域や異常部分を検出するという点で課題と解決手段に共通性がある。

第2のタイプは、異質解決策型である。これは、課題文脈には一定の関連があるが、対象物、材料、工程、利用分野が大きく異なる候補である。実験2では、洗浄・除去系技術から半導体洗浄への候補抽出を異質解決策型として扱う。洗浄や残渣除去という課題には関連がある一方で、対象物や工程は大きく異なるため、結果は補助分析として扱う。

本研究では、実験1を主分析、実験2を補助分析として位置づける。実験1では、既知の代表的手法であるU-Netを対象に、提案手法が専門家確認候補を抽出できるかを検討する。実験2では、より異質な対象に対して、課題文脈を手がかりに候補を整理できるかを探索的に確認する。

3.8 本手法の位置づけ

本節では、本手法の研究上の位置づけを整理する。本研究の目的は、特許文書から技術導入可能性を直接判断することではない。また、候補が将来必ず対象分野で使われることを示すものでもない。

本手法は、専門家が確認すべき候補を抽出するスクリーニング手法として位置づける。すなわち、膨大な特許文書の中から、課題文脈が近く、対象分野で低出現または未使用である技術手法・解決手段を抽出し、専門家が読むべき候補を絞り込むことを目的とする。

この位置づけにおいて、課題文脈と解決手段文脈を分離することには2つの意義がある。第一に、候補抽出理由を説明しやすくなる。単に全文が似ているから候補になったのではなく、どの課題が近いのか、どの解決手段が提示されているのかを分けて確認できる。第二に、異分野間で対象物や分野名が異なる場合でも、課題の近さに着目して候補を抽出しやすくなる。

一方で、本手法には限界もある。LLM による文脈抽出には誤差があり、特許文書は実装や商用化を保証するものではない。また、人手評価は候補の解釈可能性を確認するものであり、大規模な専門家評価とは異なる。したがって、本研究の結果は、専門家確認候補を抽出するスクリーニング手法としての有効性を検討するものとして解釈する必要がある。

以上の方針に基づき、次章以降では、実験1としてU-Netを対象とした近接解決策型候補抽出を、実験2として洗浄・除去系技術を対象とした異質解決策型候補抽出を検討する。

第 4 章 データセットと実験設計

4.1 本章の概要

本章では、第 3 章で述べた提案手法を検証するために用いたデータセットと実験設計について説明する。具体的には、実験 1 で用いる医療画像解析分野および製造欠陥検出分野のデータ、実験 2 で用いる洗浄・除去系技術および半導体洗浄関連データ、期間分割、ベースライン比較、評価方法を整理する。

本章の目的は、実験結果そのものを詳述することではなく、第 5 章および第 6 章で述べる結果を理解するための前提を示すことである。そのため、ここではデータセットの役割、比較対象、評価単位、候補抽出の流れを中心に説明し、詳細な数値結果や評価結果は後続の章で扱う。

本研究では、実験 1 を U-Net を対象とした近接解決策型の主分析、実験 2 を洗浄・除去系技術から半導体洗浄への異質解決策型の補助分析として位置づける。いずれの実験においても、候補は技術導入可能性を示すものではなく、専門家が確認すべき候補として扱う。

4.2 使用データセットの全体像

本節では、本研究で使用するデータセットの全体像を説明する。データセットは、実験 1 で用いる A0/A1/B0/B1 と、実験 2 で用いる C1/S1/S0_pre/S0_pre_filtered に大きく分けられる。

表 4.1 に、本研究で用いる主要データセットの概要を示す。実験 1 では、医療画像解析分野と製造欠陥検出分野を対象とし、過去期間と将来評価期間に分けて整理する。実験 2 では、半導体洗浄関連の既知事例と、花王の洗浄・除去系技術に関する非半導体候補を用いる。

表 4.1: 本研究で用いた主要データセットの概要

データセット	使用実験	内容	公開公報数	ファミリー数・候補行数
A0	実験 1 (主分析)	医療画像解析分野	54100	30093
A1	実験 1 (主分析)	医療画像解析分野の U-Net 関連集合	4028	2692
B0	実験 1 (主分析)	製造欠陥検出分野	44364	28450
B1	実験 1 (主分析)	製造欠陥検出分野の U-Net 関連集合	859	610
C1	実験 2 (補助分析)	花王の洗浄・除去系非半導体候補	522	522
S1	実験 2 (補助分析)	半導体洗浄関連の既知事例・用途クラスタ	311	23
S0_pre	実験 2 (補助分析)	クラスタ初出日前の S0 比較集合		72373
S0_pre_filtered	実験 2 (補助分析)	用途語フィルタ後の S0 比較集合		10786

注：S0_pre および S0_pre_filtered の件数は、クラスタ別に展開した行数であり、ユニークファミリー数ではない。

実験 1 における A0 は医療画像解析分野のデータであり、A1 は医療画像解析分野における U-Net 関連集合である。B0 は製造欠陥検出分野のデータであり、B1 は製造欠陥検出分野における U-Net 関連集合である。A0/B0 は、過去期間における候補抽出および分野間比較の基礎となる。A1/B1 は、U-Net 関連技術の将来期間における出現状況を確認するために用いる。

なお、A1 および B1 は、U-Net 関連語を含む広義の抽出集合である。一方、表 5.1 の U-Net 出現件数は、実験 1 の期間分割および最終フィルタを適用した後の集計値である。そのため、表 4.1 の A1/B1 件数と表 5.1 の U-Net 出現件数は、集計条件が異なる。

実験 2 における S1 は、半導体洗浄に関係する既知事例である。S1 は用途に基づいて 7 つのクラスタに分類される。C1 は、花王の洗浄・除去系技術のうち、半導体直接用途ではない候補集合である。また、S0_pre および S0_pre_filtered は、各 S1 クラスタの初出日以前に存在する S0 側の比較用集合であり、クラスタごとの課題文脈を作るために用いる。

4.3 実験 1 のデータセットと設計

本節では、実験 1 のデータセットと設計を説明する。実験 1 は、本研究の主分析であり、U-Net を対象とした近接解決策型の候補抽出を検証

表 4.2: 実験 1 におけるデータセットと期間分割

分野	集計単位	総件数	過去期間	将来期間	テキスト利用
A0	公開公報	54100	10147	43953	可
A0	ファミリー	30093	4550	25543	可
B0	公開公報	44364	4307	40057	可
B0	ファミリー	28450	2231	26219	可

する。

実験1では、医療画像解析分野をA系列、製造欠陥検出分野をB系列として整理する。A0は医療画像解析分野の過去側データ、A1は医療画像解析分野におけるU-Net関連集合である。B0は製造欠陥検出分野の過去側データ、B1は製造欠陥検出分野におけるU-Net関連集合である。

この設計の目的は、医療画像解析分野で先行して用いられたU-Net関連技術が、製造欠陥検出分野において専門家確認候補として抽出できるかを確認することである。医療画像解析と製造欠陥検出は対象分野は異なるが、画像中の対象領域や異常部分を検出するという課題に共通性がある。そのため、本研究では実験1を近接解決策型の分析として扱う。

実験1では、公開公報単位およびファミリー単位の両方でデータを整理する。特許文書は同一発明に対して複数の公開公報を持つ場合があるため、ファミリー単位で整理することにより、重複の影響を抑えた候補評価が可能になる。また、過去期間と将来評価期間を分けることで、過去時点で観測可能な情報から、後に対象分野で確認される代表的手法を専門家確認候補として抽出できるかを検討する。

表4.2に、実験1で用いたデータセットと時系列分割の概要を示す。ここでは、データセットの構成を示すにとどめ、U-Netの出現傾向や候補抽出結果は第5章で詳述する。

4.4 実験2のデータセットと設計

本節では、実験2のデータセットと設計を説明する。実験2は、本研究の補助分析であり、洗浄・除去系技術から半導体洗浄への異質解決策型候補抽出を検討する。

実験2では、半導体洗浄に関する既知事例をS1として整理する。S1は用途に基づき、7つの用途クラスタに分類する。クラスタには、シリコンウェーハ洗浄、半導体基板洗浄、CMP後洗浄、フラックス・電子部品洗浄、フォトレジスト・樹脂マスク除去、接着剤洗浄、回路基板洗浄が含まれる。各クラスタについて、クラスタ内で最も早い日付を基準として、事前に存在する候補集合を作成する。

C1 は、花王の洗浄・除去系技術に関する非半導体候補集合である。C1からは、S1と同一ファミリーに該当するものや、半導体直接語を含むものを除外する。ただし、`substrate` のように単独では半導体用途を直接示すとは限らない語については、除外ではなく確認用フラグとして扱う。

また、S0_preおよびS0_pre_filteredを用いて、各クラスタの課題文脈に対応する比較用集合を作成する。S0_preはクラスタ初出日以前のS0側候補であり、S0_pre_filteredはクラスタごとの用途語フィルタを適用した集合である。このS0側の文脈を用いて、各クラスタに対してC1候補をランキングする。

実験2では、7クラスタそれぞれについて上位20件の候補を抽出する。これにより、各クラスタ上位20件、7クラスタ分の候補が得られる。その後、同一ファミリーの重複を統合し、46件のユニークファミリーを評価対象とする。この評価対象に対して、LLM支援付き著者確認評価を行う。

本実験は、花王の洗浄・除去系技術が半導体洗浄へ導入可能であることを示すものではない。あくまで、洗浄・除去という課題文脈を手がかりに、半導体洗浄課題と接続しうる専門家確認候補を抽出できるかを確認する補助分析である。

4.5 ベースライン比較の設計

本節では、本研究で用いるベースライン比較の設計を説明する。ベースライン比較は、提案手法がすべてのベースラインに単純に優越することを示すためのものではない。むしろ、候補抽出方法によって得られる候補集合の性質がどのように異なるかを確認するために用いる。

実験1では、提案手法による候補集合に加えて、全文ベクトル系の候補、低ランクベースライン、ランダムベースライン、頻度ベースラインなどを比較対象とする。ここで注意すべき点は、`true_random`や`frequency`ベースラインが高く見える場合があることである。これは、B0自体が製造欠陥検出分野であり、直接的に対象分野に属する候補を含むためである。したがって、ベースライン比較は単純な勝敗ではなく、候補集合の性質や説明可能性を比較するものとして解釈する必要がある。

実験2では、提案手法による課題文脈ベースのランキングと、Title、Abstract、Claimsを用いた軽量全文テキストベースラインを補助的に比較する。このベースラインは、厳密なBERT型全文埋め込み実験ではない。全文テキストを用いた軽量の比較により、課題文脈に基づくランキングと、全文テキスト類似に基づくランキングがどの程度異なる候補集合を提示するかを確認する。

実験2のベースライン比較も、技術導入可能性を判断するためのものではない。提案手法が提示する候補集合と、全文テキスト類似に基づく候補集合の違いを把握するための補助分析として扱う。

4.6 評価方法

本節では、本研究における候補評価の方法を説明する。評価は、LLM支援付き著者確認評価として行う。ここでLLMは、特許文書の課題文脈や解決手段文脈を整理する支援として用いられるが、候補の最終的な妥当性を単独で判定するものではない。

評価では、抽出された候補が専門家確認候補としてどの程度解釈可

能かを確認する。候補には、◎ / ○ / △ / ×のラベルを付与する。◎は対象課題との接続が強く、代表例として説明しやすい候補を表す。○は専門家確認候補として妥当な候補を表す。△は課題や効果に一部近さがあるが、対象物や工程、解決手段の対応が弱い候補を表す。×は専門家確認候補としての対応が読み取りにくい候補を表す。

この評価は、候補が実際に対象分野へ導入できるかを確認するものではない。特許文書から読み取れる範囲で、専門家が確認すべき候補として解釈可能かを判断するものである。したがって、本研究の評価結果は、スクリーニング手法としての有効性を検討するためのものである。

実験1では、U-Netを中心とした近接解決策型候補について、候補集合ごとの評価を行う。実験2では、46件のユニークファミリーを対象に、異質解決策型候補としての解釈可能性を確認する。詳細な評価結果は、第5章および第6章で述べる。

4.7 実験設計上の注意

本節では、本研究の実験設計を解釈するうえで注意すべき点を整理する。第一に、本研究は技術導入可能性を直接示すものではない。抽出された候補は、専門家が確認すべき候補であり、実装、商用化、採用、技術移転を保証するものではない。

第二に、LLMによる文脈抽出には誤差が含まれる可能性がある。LLMは文脈整理を支援するために用いており、候補の最終判定者ではない。そのため、抽出結果は人手評価によって確認する必要がある。

第三に、実験1と実験2は同じ重みの分析ではない。実験1はU-Netを対象とした近接解決策型の主分析であり、本研究の中心的な検証である。一方、実験2は洗浄・除去系技術から半導体洗浄への異質解決策型の補助分析であり、より探索的な位置づけである。

第四に、ベースライン比較の解釈にも注意が必要である。実験1では、ベースラインによっては直接的に対象分野に近い候補を含むため、数

値が高く見える場合がある。したがって、ベースライン比較は提案手法の単純な勝敗を示すものではなく、候補集合の性質を比較するために用いる。実験2の軽量全文テキストベースラインも、補助的な比較であり、厳密なBERT型全文埋め込み実験ではない。

以上の設計に基づき、第5章では主分析である実験1の結果を述べ、第6章では補助分析である実験2の結果を述べる。

第5章 実験1：U-Netを対象とした近接 解決策型候補抽出

5.1 本章の概要

本章では、本卒論の主分析として、U-Netを対象とした近接解決策型の候補抽出を検証する。参照分野を医療画像解析分野、対象分野を製造欠陥検出分野とし、医療画像解析分野で先行して現れたU-Net関連技術が、製造欠陥検出分野における専門家確認候補として抽出できるかを確認する。

本実験では、特許文書を全文ベクトルとして扱うのではなく、`problem_context`と `solution_context` に分離して候補を抽出する。これにより、単に文書全体が似ている候補ではなく、「どの課題が近く、どの解決手段が候補として提示されるのか」を説明しやすくすることを目指す。

なお、本章の結果は、医療画像解析分野から製造欠陥検出分野への技術移転の因果関係を示すものではない。本実験は、後ろ向き評価として、過去期間の特許情報から専門家が確認すべき候補を抽出できるかを確認するものである。

実験1フロー：U-Netを対象とした近接解決策型



図 5.1: 実験1の処理フロー。U-Netを対象とした近接解決策型候補抽出を主分析として扱う。

5.2 実験1の目的

本節では、実験1の目的と位置づけを説明する。実験1は、本研究における主分析であり、近接解決策型の候補抽出を検証するために行う。

本実験で対象とするU-Netは、医療画像解析分野で広く用いられてきた画像セグメンテーション手法である。医療画像解析では、臓器、病変、組織領域などを画像中から抽出する課題が多く存在する。一方、製造欠陥検出分野でも、製品表面や材料画像から欠陥領域を検出する課題が存在する。両者は対象分野は異なるが、画像中の対象領域や異常領域を検出するという点で課題が近い。

このため、本研究ではU-Netを、医療画像解析分野から製造欠陥検出分野への近接解決策型候補抽出の代表例として扱う。ここでの目的は、U-Net が実際にどのような経路で導入されたかを示すことではなく、過去期間の特許文書に基づいて、U-Net 関連技術を専門家確認候補として抽出できるかを確認することである。

実験1では、課題文脈と解決手段文脈の分離に基づくランキングを用いる。全文類似に基づく方法では、対象物や分野名の違いが強く影響し、候補抽出理由が説明しにくい場合がある。これに対して、本研究では、課題文脈の近さと解決手段としてのU-Net 関連技術に注目し、候補抽出理由を説明しやすい形で整理する。

5.3 データセットと期間設定

本節では、実験1で用いるデータセットと期間設定を説明する。実験1では、A0/A1/B0/B1の4種類のデータを用いる。

A0 は医療画像解析分野全体のデータであり、A1 は医療画像解析分野における U-Net 関連集合である。B0 は製造欠陥検出分野全体のデータであり、B1 は製造欠陥検出分野における U-Net 関連集合である。A0/B0 は候補抽出および分野間比較の基礎となるデータであり、A1/B1はU-Net関連技術の出現状況を確認するために用いる。




図 5.2: U-Net の年次出現傾向。医療画像解析分野と製造欠陥検出分野における出現時期の違いを後ろ向き評価の前提として示す。

表 4.2 に、実験1のデータセットと時系列分割を示す。公開公報単位では、A0 は 54,100 件、B0 は 44,364 件である。ファミリー単位では、A0 は 30,093 件、B0 は 28,450 件である。また、過去期間と将来期間に分けて整理し、過去期間における候補抽出と、後年の対象分野における出現状況に対応づけて確認する。

この期間設定は、将来の出現を事前に当てることを目的とするものではない。後ろ向き評価として、過去時点の情報に基づいて、後年に対象分野で確認される代表的手法を専門家確認候補として抽出できるかを検討するための設計である。

5.4 U-Net の出現傾向

本節では、医療画像解析分野および製造欠陥検出分野における U-Net 関連特許の出現傾向を確認する。ここでは、U-Net が実験1の対象として妥当かを確認するために、年次出現件数と分野別の出現状況を整理する。

図 5.2 に、U-Net 関連特許の年次出現件数を示す。医療画像解析分野で

表 5.1: 実験 1 における U-Net 出現状況

分野	集計単位	U-Net 総件数	U-Net 出現率	過去期間	将来期間
A0	公開公報	1610	0.030	55	1555
A0	ファミリー	1133	0.038	33	1100
B0	公開公報	314	0.007	0	314
B0	ファミリー	233	0.008	0	233

は、U-Net 関連特許が先行して増加している。一方、製造欠陥検出分野では、医療画像解析分野より後の時期に U-Net 関連特許が確認される。この傾向は、U-Net を近接解決策型候補抽出の代表例として扱う根拠となる。

表 5.1 に、U-Net 関連特許の出現件数と出現率を示す。公開公報単位では、A0 における U-Net 関連特許は 1,610 件、B0 では 314 件である。ファミリー単位では、A0 における U-Net 関連特許は 1,133 件、B0 では 233 件である。過去期間においては A0 側に U-Net 関連特許が存在する一方、B0 側では将来期間に U-Net 関連特許が確認される。

ただし、この出現傾向は、U-Net が一方の分野から他方の分野へ直接移ったことを示すものではない。本研究では、このような時系列上の関係を、後ろ向き評価の設定として利用する。すなわち、過去期間の文脈から、後年に対象分野で現れる代表的手法を専門家確認候補として抽出できるかを確認する。

5.5 候補抽出結果

本節では、提案手法による候補抽出結果を示す。ここでは、U-Net 関連技術が候補ランキング上でどの位置に現れるかを確認する。

表 5.2 に、U-Net 候補抽出に関する後ろ向き確認結果を示す。過去期間の具体的手法ランキングにおいて、U-Net は 2 位に位置づけられた。したがって、U-Net は上位 3 件以内に含まれており、専門家確認候補として十分上位に抽出されたといえる。また、A0 過去期間では U-Net 関連特許が

表 5.2: U-Net 候補抽出に関する後ろ向き確認結果

項目	値	解釈
U-Net 候補ランキング順位	2 位	過去期間の具体的手法ランキングで上位に抽出された
上位 3 件以内の抽出	該当	専門家確認候補として十分上位に含まれた
A0 過去 U-Net 出現件数	55 件	医療画像解析分野の過去期間で確認された
B0 過去 U-Net 出現件数	0 件	製造欠陥検出分野の過去期間では確認されなかった
B0 将来 U-Net 出現件数	314 件	製造欠陥検出分野の将来期間で確認された
評価の位置づけ	後ろ向き評価	将来予測ではなく、既知の後年出現を用いた確認である

55 件確認された一方、B0 過去期間では確認されず、B0 将来期間では 314 件確認された。

具体的手法に限定したランキングでは、各手法 m について、参照分野 A0 の過去期間における出現率 $\text{rate_A0}(m)$ と、対象分野 B0 の過去期間における出現率 $\text{rate_B0}(m)$ を計算し、その差分 $\text{gap}(m) = \text{rate_A0}(m) - \text{rate_B0}(m)$ を用いた。この差分が大きい手法は、A0 側では相対的に出現している一方、B0 側では過去期間にまだ低出現である候補として解釈できる。

本研究で U-Net を代表例として扱う理由は、CNN のような汎用的な画像処理語に比べ、U-Net が医療画像セグメンテーションと結びついた具体的手法であり、かつ B0 過去期間では確認されなかったためである。すなわち、U-Net は近接解決策型の後ろ向き評価において、参照分野で先行し、対象分野では後年確認される代表的手法として扱いやすい。

この結果は、提案手法が U-Net 関連技術を専門家確認候補として上位に抽出できることを示すものである。ただし、これは将来の技術採用を当てたという意味ではない。あくまで、後ろ向き評価として、医療画像解析分野で先行して現れた U-Net 関連技術を、製造欠陥検出分野における近接課題の候補として抽出できるかを確認した結果である。

候補抽出の観点では、U-Net は単なるキーワードではなく、画像中の領域抽出や欠陥検出に関係する具体的な解決手段として扱われる。したがって、`problem_context` と `solution_context` を分けることで、候補が抽




図 5.3: 実験 1 における提案手法と全文類似上位ベースラインの比較。単純な優劣ではなく、候補集合の性質差を確認する補助比較として扱う。

表 5.3: 実験 1 における提案手法と全文類似上位ベースラインの比較

候補集合	N	平均スコア	妥当候補率	◎	○	△	×
全文類似上位ベースライン	30	0.567	0.167	1	4	6	19
提案手法	23	1.61	0.522	5	7	8	3

出された理由を「課題が近い」「解決手段としてU-Net系技術が提示されている」という形で説明しやすくなる。

5.6 ベースライン比較

本節では、提案手法と全文類似上位ベースラインを比較する。ベースライン比較は、提案手法の単純な優劣を示すためのものではない。候補抽出方法によって得られる候補集合の性質がどのように異なるかを確認するために行う。

図 5.3 に、提案手法と全文類似上位ベースラインの平均スコアと妥当候補率を示す。また、表 5.3 に、同じ 2 集合の評価結果を示す。提案手法は 23 件であり、平均スコアは 1.61、妥当候補率は 0.522 であった。評価ラベルの内訳は、◎ が 5 件、○ が 7 件、△ が 8 件、× が 3 件であった。

全文類似上位ベースラインは30件であり、平均スコアは0.567、妥当候補率は0.167であった。評価ラベルの内訳は、◎が1件、○が4件、△が6件、×が19件であった。全文類似上位ベースラインでは×が多く、全文全体の類似度のみでは専門家確認候補として弱い候補が多く含まれることが確認された。一方、提案手法では×が少なく、◎、○、△を含む確認候補が多く得られた。

ただし、本比較は提案手法の単純な精度優位を示すものではなく、候補集合の性質差を確認する補助比較として位置づける。本研究で重視するのは、課題文脈・解決手段文脈に基づいて、候補抽出理由を説明できる形で専門家確認候補を提示できるかである。提案手法の意義は、候補のスコアだけでなく、候補がどの課題文脈に基づいて抽出され、どの解決手段として読めるのかを整理できる点にある。

なお、B0内頻出手法やランダム抽出候補は、対象分野内での直接的な適合度を確認する参考集合としては有用である。しかし、本研究の主目的である、参照分野で先行し対象分野では過去時点で低出現である候補の抽出とは評価条件が異なる。そのため、本文の主比較では、提案手法と全文類似上位ベースラインの比較に焦点を当てる。

5.7 LLM 支援付き著者確認評価

本節では、実験1における人手評価の位置づけを説明する。本研究では、候補の評価をLLM支援付き著者確認評価として行った。LLMは、候補文書の課題文脈、解決手段文脈、技術手段などを整理するために用いたが、候補の最終的な評価を単独で決めるものではない。

評価では、候補が専門家確認候補としてどの程度解釈可能かを確認した。評価ラベルは、強い候補、妥当な候補、弱い候補、不適切な候補を区別するために用いた。また、候補スコアや代表候補フラグを用いて、卒論本文で説明しやすい候補を整理した。

実験1全体では、提案手法による候補だけでなく、ベースライン候補も含めて評価対象とした。これは、候補抽出方法ごとの特徴を比較す

るためである。評価結果では、B0 分野に直接由来するベースラインが高く評価される場合も見られた。そのため、評価結果は単純な手法間の勝敗ではなく、各候補集合がどのような性質を持つかを理解するために用いる。

本評価は、完全な第三者評価や大規模な専門家評価ではない。したがって、本章の結果は、専門家確認候補を抽出するスクリーニング手法としての有効性を検討するためのものとして解釈する必要がある。

5.8 実験 1 のまとめ

本節では、実験1の結果を簡潔にまとめる。実験1は、本卒論の主分析として、U-Netを対象とした近接解決策型候補抽出を検証した。

まず、U-Net 関連特許は医療画像解析分野で先行して現れ、製造欠陥検出分野では後年に確認された。このため、U-Net は近接解決策型候補抽出の後ろ向き評価対象として扱うことができる。

次に、提案手法による候補抽出では、U-Net が過去期間ランキングで2位となり、上位候補として確認された。これは、課題文脈・解決手段文脈に基づくランキングにより、U-Net 関連技術を専門家確認候補として抽出できることを示唆する。

さらに、ベースライン比較から、候補抽出方法によって候補集合の性質が異なることが確認された。全文類似上位ベースラインでは不適切候補が多く含まれ、全文全体の類似度のみでは専門家確認候補として弱い候補が混入しやすいことが確認された。ただし、単純なスコア比較だけで手法の良し悪しを判断することはできない。本研究の主張は、単純な precision の優位ではなく、課題文脈と解決手段文脈を分けることで、候補抽出理由を説明しやすい専門家確認候補を提示できる点にある。

以上より、実験1では、近接解決策型の主分析として、課題文脈・解決手段文脈分離に基づく候補抽出が、専門家確認候補を整理するスクリーニング手法として有効に働く可能性が示唆された。次章では、補助分析

として、洗浄・除去系技術から半導体洗浄への異質解決策型候補抽出を検討する。


第 6 章 実験 2：洗浄・除去系技術を対象とした異質解決策型補助分析

6.1 本章の概要

本章では、卒論の補助分析として、洗浄・除去系技術から半導体洗浄に接続しうる異質解決策型の専門家確認候補を抽出できるかを確認する。第5章では、U-Netを対象とした近接解決策型の主分析を行った。これに対して本章では、対象物や工程がより異なる場合に、課題文脈を手がかりとして候補を整理できるかを検討する。

本章で扱う実験2は、技術導入可能性や企業行動を示すものではない。花王の洗浄・除去系特許を用いるが、これは企業の将来行動を論じるためではなく、洗浄・除去という課題文脈を持つ特許集合から、半導体洗浄課題との対応を専門家が確認すべき候補として整理できるか

実験2フロー：異質解決策型の補助分析



目的：技術導入可能性の証明ではなく、専門家確認候補を抽出する。

図 6.1: 実験 2 の処理フロー。S1 用途クラスタ、C1 非半導体系 pre 候補、各クラスタ上位 20 件、7 クラスタ分、ファミリー単位の重複統合、46 件の LLM 支援付き著者確認評価を示す。

を確認するためである。

本章では、まず実験2の目的を述べ、次にS1用途クラスタ、C1候補母集団、クラスタ別候補ランキングの作成手順を説明する。その後、46件のユニークファミリーを対象としたLLM支援付き著者確認評価の結果を示し、最後に軽量全文テキストベースラインとの補助比較を行う。

6.2 実験2の目的

本節では、実験2の目的と位置づけを説明する。実験2は、本卒論の補助分析であり、洗浄・除去系技術から半導体洗浄への異質解決策型候補抽出を検討する。

実験1では、医療画像解析と製造欠陥検出のように、課題と解決手段の両方に比較的近さがある設定を扱った。一方、実験2では、洗浄・除去という課題には一定の関連があるものの、対象物、工程、材料、利用分野が大きく異なる候補を扱う。このような設定では、全文類似だけでは候補抽出の理由が説明しにくく、課題文脈と解決手段文脈を分けて整理する必要がある。

本実験の目的は、半導体洗浄課題との接続が読み取れる専門家確認候補を抽出できるかを確認することである。したがって、本実験は、特定企業の半導体分野への進出や、候補技術の実装可能性を示すものではない。あくまで、既知事例に関連する候補集合を人間が読んだときに、半導体洗浄課題との対応を解釈できるかを確認する補助分析である。

なお、実験2は、実運用における未知候補推薦そのものを再現したものではなく、既知事例を用いた後ろ向き評価として位置づける。実運用では、対象分野の特許集合から課題文脈を抽出し、課題クラスタを作成したうえで、他分野の候補を探索することが想定される。一方、本実験では、花王の半導体洗浄関連既知事例であるS1を用途クラスタに整理し、そのクラスタに対応する課題文脈に対して、C1の非半導体系洗浄・

除去技術から候補を抽出した。したがって、本実験の結果は企業進出予測ではなく、異質解決策型候補抽出が専門家確認候補を提示しうるかを確認する補助分析として解釈する。

6.3 S1 用途クラスタの構成

本節では、半導体洗浄に関する既知事例であるS1を、用途クラスタに分類する方法を説明する。実験2では、S1を半導体洗浄側の参照集合として用い、その用途に基づいて7つのクラスタを作成した。

本研究で用いた7つの用途クラスタは、以下の通りである。

- 接着剤洗浄クラスタ
- 回路基板洗浄クラスタ
- CMP後洗浄クラスタ
- フラックス・電子部品洗浄クラスタ
- フォトレジスト・樹脂除去クラスタ
- 半導体基板洗浄クラスタ
- シリコンウェーハ洗浄クラスタ

各クラスタは、半導体洗浄や電子部品洗浄に関連する用途の違いを表す。例えば、シリコンウェーハ洗浄、半導体基板洗浄、CMPまたは研磨後洗浄、フラックス残渣や電子部品洗浄などに対応する。

各クラスタについて、クラスタ内のS1ファミリーのうち最も早い日付をクラスタ初出日として設定した。このクラスタ初出日は、後続のC1 候補抽出において、既知事例より前に存在する候補を抽出するための時系列条件として用いる。

このクラスタ化は、実験2の候補抽出を用途別に比較するための設計である。クラスタごとに課題や対象物が異なるため、候補の解釈可能性にも差が生じる可能性がある。

6.4 C1 候補母集団の作成

本節では、実験2におけるC1候補母集団の作成方法を説明する。C1は、花王の洗浄・除去系技術に関する特許集合のうち、半導体直接用途ではない先行候補を抽出するために用いる。

まず、S1 と同一ファミリーに該当するものは除外した。これは、既知の半導体洗浄事例そのものが候補集合に混入することを避けるためである。次に、半導体直接語を含むものを除外した。実験2の目的は、半導体用途として既に明示されている特許を再発見することではなく、非半導体系の洗浄・除去技術から、半導体洗浄課題に接続しうる専門家確認候補を抽出することであるためである。

ただし、`substrate`のような語は、単独では半導体用途を直接示すとは限らない。そのため、`substrate`単独の出現は除外条件とはせず、確認用フラグとして扱った。これにより、基板という語を含むが半導体直接用途とは限らない候補を、人手確認の対象として残すことができる。

また、各S1クラスタの初出日を基準として、それ以前に存在するC1候補を抽出した。これにより、各クラスタの既知事例より前に存在する非半導体系の候補を、クラスタ別にランキングする準備を行った。

このC1候補母集団は、専門家確認候補を作るための前処理済み集合であり、候補の妥当性をこの段階で判断するものではない。候補が半導体洗浄課題に接続しうるかどうかは、後続のランキングと人手評価により確認する。

6.5 クラスタ別候補ランキング

本節では、S1用途クラスタごとにC1候補をランキングする方法を説明する。実験2では、7クラスタそれぞれについて、課題文脈に基づく候補ランキングを作成した。

まず、各クラスタに対して、クラスタ初出日以前に存在するS0側の比較用集合を作成した。次に、用途語フィルタを用いて、各クラスタの課

題に対応しやすいS0_pre_filteredを作成した。これにより、クラスタごとの課題文脈をより明確にし、その文脈をもとにC1候補をランキングできるようにした。

各 S1 用途クラスタについて、クラスタに対応する S0_pre_filtered の problem_context を収集し、これを対象分野側の課題文脈として扱った。次に、これらの problem_context をBERT系モデルによりベクトル化し、クラスタごとの課題文脈を表すベクトル集合を作成した。さらに、C1 候補の problem_context も同様にベクトル化し、両者の類似度に基づいてクラスタ別ランキングを作成した。これにより、半導体用途そのものではないが、半導体洗浄課題と類似した課題を扱う洗浄・除去系特許を専門家確認候補として抽出した。

なお、このランキングは候補の技術導入可能性を判定するものではない。上位候補については、solution_context、technical_means、target_objectを確認し、半導体洗浄課題との対応が解釈可能かをLLM支援付き著者確認評価により確認した。

その後、各クラスタについてC1候補をランキングし、上位20件の候補を抽出した。7クラスタそれぞれで上位20件を抽出するため、各クラスタ上位20件、7クラスタ分の候補が得られる。ただし、同一ファミリーが複数クラスタに出現する場合があるため、最終的にはファミリー単位で重複統合を行った。

重複統合の結果、46件のユニークファミリーをLLM支援付き著者確認評価の対象とした。この46ファミリーは、提案手法により抽出された実験2の評価対象である。ただし、この時点では候補の妥当性を確定するものではなく、専門家確認候補として人間が読むための候補集合である。

6.6 LLM 支援付き著者確認評価

本節では、実験2で抽出した46件のユニークファミリーに対するLLM支援付き著者確認評価の結果を示す。評価では、候補が半導体洗浄課題




図 6.2: 実験 2 における評価ラベルの分布。46 件のユニークファミリーを対象にした LLM 支援付き著者確認評価の結果を示す。




図 6.3: 実験 2 におけるクラスタ別評価ラベル分布。クラスタ依存性を確認するための補助図である。

表 6.1: 実験 2 における LLM 支援付き著者確認評価の全体集計

ラベル	意味	件数
◎	強い候補	11
○	妥当候補	5
△	弱い候補	12
×	不適切候補	18
◎ + ○	強い候補または妥当候補	16
◎ + ○ + △	広義の確認候補	28

表 6.2: 実験 2 におけるクラスタ別評価集計

クラスタ	N	◎	○	△	×	◎ + ○	◎ + ○ + △
接着剤洗浄	7	2	0	0	5	2	2
回路基板洗浄	3	1	1	1	0	2	3
CMP 後洗浄	12	0	0	5	7	0	5
フラックス・電子部品洗浄	5	1	1	2	1	2	4
フォトレジスト・樹脂除去	6	2	0	2	2	2	4
半導体基板洗浄	6	5	1	0	0	6	6
シリコンウェーハ洗浄	7	0	2	2	3	2	4

との対応を専門家確認候補として解釈できるかを確認した。

評価ラベルは、◎、○、△、×の4段階とした。◎は半導体洗浄、基板洗浄、残渣除去などに直接接続しうる強い候補を表す。○は精密洗浄、電子部品、材料表面処理など、周辺領域として接続しうる候補を表す。△は課題や効果は近いが、対象物、工程、解決手段の対応が弱い候補を表す。×は、異質解決策候補としての対応が読み取りにくい候補を表す。

図 6.2 および表 6.1 に、最終評価の全体分布を示す。46 件のうち、◎は 11 件、○は 5 件、△は 12 件、×は 18 件であった。◎+○は 16 件であり、強い候補または妥当な専門家確認候補として扱える候補が一定数得られた。また、◎+○+△は 28 件であり、広義には確認対象として残しうる候補も含まれている。

一方で、×も 18 件含まれており、全体としてノイズは多い。これは、異質解決策型の候補抽出では、洗浄・除去という課題が近くても、対象物や汚れの種類、工程条件が異なるため、半導体洗浄課題との対応が読み

表 6.3: 実験 2 における提案手法と軽量全文テキストベースラインの比較

指標	内容	値
提案手法件数	提案手法のファミリー数	46
ベースライン件数	軽量全文テキストベースラインのファミリー数	56
重複件数	重複ファミリー数	11
提案手法のみ	提案手法にのみ含まれるファミリー数	35
ベースラインのみ	ベースラインにのみ含まれるファミリー数	45

取りにくい候補が混入しやすいためである。

図 6.3 および 表 6.2 に、クラスタ別の評価結果を示す。半導体基板洗浄クラスタでは 6 件中 5 件が ◎、1 件が ○ であり、強い候補が多く得られた。これは、基板洗浄という対象や課題が半導体洗浄と比較的近いため、候補の対応関係を読み取りやすかったためと考えられる。

一方、CMP 後洗浄クラスタでは 12 件中 ◎ と ○ が 0 件であり、△ が 5 件、× が 7 件であった。このクラスタでは、CMP 後洗浄という工程固有性が強く、非半導体系の洗浄・除去技術から直接対応を読み取ることが難しい候補が多かった。接着剤洗浄クラスタでも 7 件中 × が 5 件であり、候補の対象物や汚染物の違いが評価に影響した。

これらの結果から、実験 2 では一部クラスタで専門家確認候補として解釈可能な候補が得られた一方、クラスタによって候補の解釈可能性に大きな差があることが確認された。したがって、異質解決策型の候補抽出では、クラスタ設計や用途語フィルタが結果に強く影響する。

6.7 軽量全文テキストベースラインとの補助比較

本節では、提案手法による候補集合と、軽量全文テキストベースラインによる候補集合を比較する。ここで用いるベースラインは、厳密な BERT 型全文埋め込み実験ではなく、Title、Abstract、Claims を用いた軽量全文テキストベースラインである。

実験 2 では、提案手法による課題文脈ベースのランキングと、全文テキストに基づく候補集合がどの程度重なるかを確認した。表 6.3 に、フ




図 6.4: 提案手法と軽量全文テキストベースラインの候補集合の重複・差分。精度優劣ではなく候補集合の傾向差を確認する。

ファミリー単位の重複比較を示す。提案手法の候補数は46ファミリー、軽量全文テキストベースラインの候補数は56ファミリーであった。このうち、重複したファミリーは11件であり、提案手法のみに含まれる候補は35件、軽量全文テキストベースラインのみに含まれる候補は45件であった。

図 6.4 に、提案手法と軽量全文テキストベースラインの重複関係を示す。重複が11件にとどまったことから、課題文脈に基づくランキングと、全文テキスト類似に基づくランキングは、異なる候補集合を提示することが分かる。これは、全文テキストでは対象物や用途語、請求項中の表現が強く影響する一方で、課題文脈ベースのランキングでは「何の課題に対応しているか」に焦点を当てるためである。

重複した11件の内訳は、◎が4件、○が3件、△が2件、×が2件であった。この内訳から、両方の方法に共通して現れる候補には一定数の強い候補や妥当候補が含まれる一方、不適切候補も含まれることが分かる。

ただし、軽量全文テキストベースラインのみに含まれる候補は未評価である。そのため、本比較から、提案手法がベースラインより精度面

で優れているとは結論づけない。本比較は、候補集合の傾向差を確認するための補助分析である。提案手法の意義は、全文テキスト類似とは異なる観点から、専門家確認候補を抽出し、その抽出理由を課題文脈に基づいて説明しやすくする点にある。

6.8 実験2のまとめ

本節では、実験2の結果を補助分析としてまとめる。実験2では、洗浄・除去系技術から半導体洗浄に接続しうる異質解決策型の専門家確認候補を抽出できるかを確認した。

まず、S1を7つの用途クラスタに分類し、各クラスタについてC1非半導体系の先行候補をランキングした。各クラスタ上位20件、7クラスタ分の候補をファミリー単位で重複統合し、46件のユニークファミリーをLLM支援付き著者確認評価の対象とした。

最終評価の結果、◎が11件、○が5件、△が12件、×が18件であった。◎+○は16件、◎+○+△は28件であり、全体としてノイズは多いものの、一部には専門家確認候補として解釈可能な候補が得られた。特に、半導体基板洗浄クラスタでは強い候補が多く、CMP後洗浄クラスタでは強い候補が少ないなど、クラスタ依存性が確認された。このことから、異質解決策型の候補抽出では、対象分野側の課題クラスタ設計が候補品質に大きく影響することが示唆された。

また、軽量全文テキストベースラインとの補助比較では、提案手法とベースラインの重複は11ファミリーにとどまった。これは、課題文脈ベースのランキングと全文テキストベースのランキングが、異なる候補集合を提示することを示している。ただし、ベースラインのみの候補は未評価であるため、本比較を手法間の精度優劣として扱うことはできない。

以上より、実験2は、異質解決策型においても、課題文脈を手がかりに専門家確認候補を整理できる可能性を補助的に示した。一方で、候補の解釈可能性はクラスタに大きく依存し、ノイズも多い。したがって、実

験2は本卒論における主結果ではなく、提案手法の適用範囲を探索的に確認する補助分析として位置づける。

第7章 考察

7.1 本章の概要

本章では、第5章の実験1および第6章の実験2の結果を踏まえ、本研究で提案した課題文脈・解決手段文脈の分離に基づくクロスドメイン技術候補抽出の意義と限界を考察する。実験1は、U-Netを対象とした近接解決策型候補抽出の主分析であり、実験2は、洗浄・除去系技術から半導体洗浄への異質解決策型候補抽出の補助分析である。

本研究の目的は、技術導入可能性を自動的に判定することではない。特許文書から課題文脈と解決手段文脈を抽出し、異分野間で専門家が確認すべき候補を絞り込むスクリーニング手法としての有効性を検討することである。本章では、実験1と実験2から得られた示唆、全文類似との違い、スクリーニング手法としての意義、限界、今後の課題を整理する。

7.2 実験1から得られた示唆

本節では、主分析である実験1から得られた示唆を整理する。実験1では、U-Netを対象として、医療画像解析分野から製造欠陥検出分野への近接解決策型候補抽出を検証した。

実験1では、医療画像解析分野で先行して現れたU-Net関連技術を対象とし、製造欠陥検出分野における後年出現を参照する後ろ向き評

表 7.1: 実験1と実験2の位置づけの比較

実験	候補タイプ	対象	評価対象	位置づけ	強み	注意点
実験1	近接解決策型	医療画像解析→製造欠陥検出	U-Net	主分析	既知手法を用いた後ろ向き評価	技術移転の因果関係は示さない
実験2	異質解決策型	洗浄・除去系技術→半導体洗浄	46件のユニークファミリー	補助分析	クラスタ別に専門家確認候補を整理	クラスタ設計に依存し、技術導入可能性は示さない

価を行った。医療画像解析と製造欠陥検出は、対象分野は異なるものの、画像中の対象領域や異常領域を検出するという課題に共通性がある。そのため、U-Netは近接解決策型の候補抽出を確認する代表例として適している。

実験1の結果から、課題文脈・解決手段文脈に基づくランキングにより、U-Net 関連技術を専門家確認候補として上位に抽出できることが確認された。U-Netは過去期間ランキングで上位に位置づけられ、上位3件以内の専門家確認候補として確認された。この結果は、過去期間の特許文書から、後年に対象分野で確認される代表的手法を専門家確認候補として抽出できる可能性を示している。

ただし、この結果は、医療画像解析分野から製造欠陥検出分野への技術移転の因果関係を示すものではない。また、将来の技術導入を予見したという意味でもない。実験1は、後ろ向き評価として、過去期間の情報に基づいて専門家確認候補を抽出できるかを確認したものである。

さらに、実験1のベースライン比較では、提案手法がすべてのベースラインに単純に優越したとは解釈しない。`true_random` や `frequency` ベースラインは、B0自体が製造欠陥検出分野であるため、直接的な分野適合度が高く見える場合がある。したがって、実験1の意義は、単純なprecisionの優位ではなく、課題文脈・解決手段文脈に基づいて候補抽出理由を説明しやすい点にある。

7.3 実験2から得られた示唆

本節では、補助分析である実験2から得られた示唆を整理する。実験2では、洗浄・除去系技術から半導体洗浄への異質解決策型候補抽出を確認した。

実験2では、S1を7つの用途クラスタに分類し、各クラスタに対してC1非半導体系の先行候補をランキングした。各クラスタ上位20件、7クラスタ分の候補からファミリー単位で重複統合を行い、46件のユニークファミリーをLLM支援付き著者確認評価の対象とした。

最終評価の結果、46件のうち◎は11件、○は5件、△は12件、×は18件であった。◎+○は16件、◎+○+△は28件であった。この結果から、全体としてノイズは多いものの、一部には専門家確認候補として解釈可能な候補が含まれていることが分かる。

クラスタ別に見ると、候補の解釈可能性には大きな差があった。半導体基板洗浄クラスタでは強い候補が多く、半導体基板洗浄に近い対象や課題を持つ候補が得られた。一方、CMP後洗浄クラスタでは強い候補が少なく、CMP後洗浄という工程固有性の強さが、非半導体系の洗浄・除去技術との対応を読み取りにくくしている可能性がある。このように、実験2ではクラスタ依存性が確認された。

このことから、異質解決策型の候補抽出では、対象分野側の課題クラスタ設計が候補品質に大きく影響することが示唆される。半導体基板洗浄クラスタのように課題や対象物が比較的近いクラスタでは良好な候補が得られやすい一方、CMP後洗浄クラスタのように工程固有性が強いクラスタでは、課題文脈が一部近くても解決手段や対象物の対応が弱くなりやすい。

実験2の結果は、洗浄・除去系技術から半導体洗浄への適用を示すものではない。また、企業行動を論じるものでもない。実験2は、対象物や工程が異なる場合でも、課題文脈を手がかりに専門家確認候補を整理できるかを確認する補助分析である。その意味で、異質解決策型では、候補抽出の可能性と同時に、ノイズやクラスタ設計への依存性も明確になった。

7.4 課題・解決手段分離の有効性

本節では、課題文脈と解決手段文脈を分離することの有効性を考察する。全文類似では、課題、対象物、解決手段、効果が同じベクトル表現の中に混在する。そのため、候補が抽出された理由を説明しにくい場合がある。

本研究では、`problem_context`を「何の課題を解いているか」、`solution_context`

を「どのように解いているか」として分離した。これにより、候補抽出の理由を、課題の近さと解決手段の内容に分けて説明できる。たとえば、実験1では、医療画像解析と製造欠陥検出の間で、画像中の対象領域や異常領域を検出するという課題の近さを確認し、その解決手段としてU-Net関連技術を候補として扱った。

実験2でも、洗浄・除去という課題文脈に着目することで、対象物や工程が異なる候補を整理することができた。全体としてノイズは多いものの、半導体基板洗浄のように課題や対象が近いクラスタでは、専門家確認候補として解釈可能な候補が得られた。

このように、課題文脈と解決手段文脈を分離することにより、「何の課題が近いのか」「どの解決手段が候補なのか」を説明しやすくなる。これは、専門家が候補を確認する際に、候補の読み方や確認すべき観点を整理するうえで有効である。

7.5 全文類似との違い

本節では、提案手法と全文類似に基づく方法との違いを考察する。全文類似は、文書全体の近さを測るうえで有用である一方、異分野技術探索においては、対象物や分野語の違いに強く影響される可能性がある。

全文類似では、課題、対象物、解決手段、効果が混在する。そのため、全文として似ている文書は得られても、その候補が「課題が近いから抽出された」のか、「対象物や用語が似ているから抽出された」のかを区別しにくい。特にクロスドメイン技術探索では、対象物や分野が異なっているにもかかわらず、解こうとしている課題が近い候補を見つけない場合がある。

実験2の軽量全文テキストベースライン比較では、提案手法46件、ベースライン56件のうち、重複は11件であった。また、提案手法のみの候補は35件、軽量全文テキストベースラインのみの候補は45件であった。この結果は、課題文脈ベースのランキングと全文テキストベースのランキングが、異なる候補集合を提示することを示している。

ただし、軽量全文テキストベースラインのみの候補は未評価である。そのため、この比較から、提案手法がベースラインより精度面で優れているとは結論づけない。本比較から言えるのは、全文テキスト類似と課題文脈ベースのランキングでは、候補集合の傾向が異なるということである。提案手法の意義は、候補抽出理由を課題文脈と解決手段文脈に分けて説明しやすくする点にある。

7.6 スクリーニング手法としての意義

本節では、本研究の提案手法をスクリーニング手法として位置づけ、その意義を考察する。本研究の手法は、技術導入可能性を自動判定するものではない。専門家が確認すべき候補を絞り込むための前段階として用いるものである。

特許文書は膨大であり、異分野の候補を人手で網羅的に確認することは難しい。そこで、課題文脈に基づいて候補を絞り込み、解決手段文脈や技術手段を整理して提示することで、専門家が読むべき候補を効率的に選ぶことができる。

実験1では、U-Netを対象とした近接解決策型において、専門家確認候補を抽出できることが確認された。実験2では、異質解決策型においても、一部クラスターで専門家確認候補として解釈可能な候補が得られた。これらの結果は、課題文脈・解決手段文脈の分離により、全文類似とは異なる候補集合を提示できる可能性を示している。

ただし、本手法によって抽出された候補は、あくまで確認対象である。実際に技術として利用できるかどうかを判断するには、専門家評価、実験的検証、事業上の判断が必要である。本研究の貢献は、その前段階として、候補探索の範囲を整理し、候補抽出理由を説明しやすくする点にある。

表 7.2: 本研究の限界

観点	限界
技術導入可能性	抽出候補が実際に導入・実装できることは示さない。
LLM 抽出	課題・解決手段・技術手段の抽出には誤抽出や一般化が含まれうる。
人手評価	評価は LLM 支援付き著者確認評価であり、大規模な第三者専門家評価ではない。
実験 2 クラスタ	異質解決策型分析は S1 用途クラスタや用途語フィルタに依存する。
特許データ	特許公開は実装、性能、市場採用、因果関係を保証しない。
ベースライン比較	実験 2 のベースラインは軽量全文テキストベースラインであり、補助比較として扱う。

7.7 本研究の限界

本節では、本研究の限界を整理する。表 7.2 に、本研究の主な限界を示す。

第一に、本研究は技術導入可能性を示すものではない。抽出された候補は、専門家確認候補であり、実装、商用化、採用、技術移転を保証するものではない。

第二に、LLM 抽出には誤差が含まれる可能性がある。`problem_context` や `solution_context` は、特許文書から抽出された中間表現であり、常に完全に正しいとは限らない。LLM は文脈整理を支援するために用いており、候補の最終評価は人手確認により行った。

第三に、人手評価は LLM 支援付き著者確認評価であり、大規模な第三者専門家評価ではない。そのため、評価結果には評価者の判断や研究目的に基づく解釈が含まれる可能性がある。今後は、複数の専門家による評価や、評価者間一致の確認が必要である。

第四に、特許文書は実装や採用を保証しない。特許に記載された技術が実際に製品化されているとは限らず、また、特許間の時系列関係が技術的影響関係を意味するわけでもない。

第五に、実験 2 はクラスタ設計に依存する。S1 の用途クラスタや用途語フィルタの設計によって、抽出される候補集合や評価結果が変わる可能性がある。特に異質解決策型では、対象物や工程の違いが大きいいため、クラスタ設計の影響は大きい。

第六に、ベースライン比較にも限界がある。実験1のベースライン比較は候補集合の性質比較であり、単純な手法間勝敗ではない。実験2の軽量全文テキストベースラインは補助比較であり、より厳密な埋め込みベースラインとの比較は今後の課題である。

7.8 今後の展望

本節では、本研究の今後の展望を述べる。第一に、第三者専門家評価の導入が必要である。本研究ではLLM支援付き著者確認評価を用いたが、候補の有用性をより厳密に確認するためには、対象分野の専門家による評価が必要である。

第二に、より厳密な埋め込みベースラインとの比較が必要である。本研究では、全文類似や軽量全文テキストベースラインとの比較を行ったが、今後は文脈ごとの埋め込みモデルや、より高度な文書表現との比較を行うことで、提案手法の特徴をより明確にできる。

第三に、他ドメインへの適用が必要である。本研究では、近接解決策型としてU-Net、異質解決策型として洗浄・除去系技術を扱った。今後は、材料、エネルギー、ロボティクス、医薬、化学プロセスなど、他の技術領域に適用し、提案手法の一般性を確認する必要がある。

第四に、技術導入可能性評価との接続が必要である。本研究はスクリーニング手法として候補を抽出するものであり、技術の実装可能性や事業上の妥当性までは扱わない。今後は、専門家評価、実験的検証、市場・事業面の評価と接続することで、候補抽出から技術検討までの一連のプロセスを設計できる可能性がある。

以上のように、本研究は、特許文書の課題文脈と解決手段文脈を分離することで、異分野間の専門家確認候補を説明可能な形で抽出するスクリーニング手法を検討した。今後は、評価の厳密化と対象領域の拡張により、より実用的な技術探索支援へ発展させることが課題である。

第 8 章 結論

8.1 本章の概要

本章では、本研究全体をまとめ、得られた示唆、限界、今後の課題を述べる。本章では新しい分析や新しい結果は追加せず、第 1 章から第 7 章までで述べた内容を整理して締めくくる。

8.2 本研究のまとめ

本研究では、特許文書の課題・解決手段分離に基づくクロスドメイン技術候補抽出を検討した。従来のように特許文書を全文ベクトルとして一括で扱うのではなく、特許文書から `problem_context` と `solution_context` を抽出し、課題文脈と解決手段文脈を分けて扱う点に特徴がある。

本研究における `problem_context` は、特許文書が「何の課題を解いているか」を表す文脈であり、`solution_context` は「どのように解いているか」を表す文脈である。この分離により、課題が近い異分野間において、対象分野では低出現または未使用である技術手法・解決手段を、専門家が確認すべき候補として抽出する枠組みを検討した。

本研究は、技術導入可能性を証明するものではない。また、将来の技術導入を予測するものでもない。本研究の位置づけは、特許文書に含まれる課題文脈と解決手段文脈を用いて、専門家確認候補を絞り込むスクリーニング手法を検討することである。

実験 1 では、U-Net を対象とした近接解決策型の主分析を行った。参照分野を医療画像解析分野、対象分野を製造欠陥検出分野とし、医療画像解析分野で先行して現れた U-Net を、製造欠陥検出分野での後年

出現を参照しながら後ろ向き評価した。U-Net は過去期間の具体的手法ランキングで2位となり、上位の専門家確認候補として抽出された。この実験は、医療画像解析から製造欠陥検出への技術移転を証明するものではなく、過去時点の特許文書から専門家確認候補を抽出できるかを確認するためのものである。

実験2では、洗浄・除去系技術から半導体洗浄への異質解決策型の補助分析を行った。S1を7用途クラスタに整理し、C1候補母集団から非半導体系の先行候補を作成したうえで、クラスタ別に候補ランキングを行った。各クラスタ上位20件、7クラスタ分の候補からファミリー単位で重複統合し、46件のユニークファミリーをLLM支援付き著者確認評価により確認した。

8.3 得られた示唆

本節では、本研究から得られた主な示唆を整理する。

第一に、課題文脈と解決手段文脈を分離することで、候補抽出理由を説明しやすくなる可能性が示された。全文類似では、課題、対象物、解決手段、効果が一つの表現に混在するため、なぜ候補が提示されたのかを説明しにくい場合がある。これに対して、本研究の枠組みでは、「何の課題が近いのか」と「どの解決手段が候補なのか」を分けて確認できる。

第二に、実験1では、U-Netを対象とした近接解決策型の候補抽出を主分析として確認した。U-Net が具体的手法ランキングで上位に抽出されたことは、過去期間の特許文書から、後年に対象分野で確認される代表的手法を専門家確認候補として提示できる可能性を示している。実験1の意義は、単純なprecisionの優位を示すことではなく、課題文脈・解決手段文脈に基づいて候補抽出理由を説明しやすい点にある。ベースライン比較も、単純な優劣を結論づけるためではなく、候補集合の性質や説明可能性を比較する補助的な分析として位置づけた。

第三に、実験2では、洗浄・除去系技術から半導体洗浄に接続しうる異質解決策型の候補抽出を補助分析として確認した。LLM支援付き著者

確認評価の結果、46件のユニークファミリーのうち、◎11件、○5件、△12件、×18件となった。ノイズも多く含まれた一方で、一部クラスタでは専門家確認候補として解釈可能な候補が得られた。

実験2では、クラスタ依存性も確認された。たとえば、半導体基板洗浄クラスタでは強い候補が多く見られた一方で、CMP後洗浄クラスタでは強候補が少ない傾向があった。このことは、異質解決策型の候補抽出では、クラスタ設計や用途語の設定が結果に大きく影響することを示している。

また、実験2の軽量全文テキストベースライン比較では、提案手法と全文テキストベースラインの候補集合に差分があることを補助的に確認した。ただし、ベースラインのみに含まれる候補は未評価であるため、提案手法が軽量全文テキストベースラインより精度面で優れているとは結論づけない。この比較から言えるのは、課題文脈・解決手段文脈の分離により、全文類似とは異なる観点から候補集合を提示できる可能性がある、という点にとどまる。

以上より、本研究は、特許文書を用いた異分野技術候補探索において、専門家確認候補を絞り込むためのスクリーニング手法として、課題文脈・解決手段文脈の分離が有用である可能性を示した。

8.4 本研究の限界

本節では、本研究の限界を整理する。

第一に、LLMによる文脈抽出には誤差が含まれる可能性がある。本研究では、Title、Abstract、Claimsを中心とした特許文書から、課題文脈、解決手段文脈、技術手段、対象物、適用分野、効果などを抽出した。しかし、LLMによる抽出は常に正確とは限らず、誤抽出、過度な一般化、重要情報の欠落が起こりうる。本研究ではLLMを最終判定者として扱っていないが、抽出結果の品質は候補ランキングに影響する。

第二に、人手評価はLLM支援付き著者確認評価であり、完全な第三者専門家評価ではない。本研究では、候補の文脈情報を整理し、著者が確

認する形で評価を行った。この評価は、候補の解釈可能性を確認するためには有用である一方で、専門家による独立評価や複数評価者間の一致度を含む評価ではない。

第三に、特許文書は技術の実装や採用を保証しない。特許が存在することは、その技術が実際に製品化されたことや事業上採用されたことを直接意味しない。また、特許は戦略的出願や防衛的出願を含む場合がある。そのため、本研究で抽出された候補は、技術導入可能性が確認されたものではなく、専門家が確認すべき候補として扱う必要がある。

第四に、実験2はクラスタ設計に依存する。S1の用途クラスタ、除外語、用途語フィルタ、pre条件などの設計は、候補集合に影響する。したがって、実験2の結果は、洗浄・除去系技術から半導体洗浄への異質解決策型候補抽出に関する補助分析として解釈すべきであり、一般的な異質解決策型候補抽出の性能を広く証明するものではない。

第五に、ベースライン比較には限界がある。実験1では、ベースラインの種類によって候補集合の性質が異なり、単純なprecisionだけで優劣を断定することは適切ではない。実験2のベースラインも、軽量全文テキストベースラインとして構成した補助比較である。そのため、ベースライン比較は、提案手法の絶対的な優位を示すものではなく、候補集合の傾向差を確認する補助的な分析として位置づける必要がある。

8.5 今後の課題

本節では、今後の課題を述べる。

第一に、第三者専門家評価を行う必要がある。本研究ではLLM支援付き著者確認評価を用いたが、候補の妥当性をより厳密に確認するためには、対象分野の専門家による評価が必要である。複数の評価者による評価や評価者間一致度の確認を行うことで、候補評価の信頼性を高めることができる。

第二に、より厳密な埋め込みベースラインとの比較が必要である。本研究では、全文類似や軽量全文テキストベースラインとの比較を行っ

たが、特許文書に特化した埋め込みモデルや、claims専用モデル、分野適応済みモデルとの比較を行うことで、提案手法の性質をより明確にできる。

第三に、LLM抽出精度の検証が必要である。本研究では、LLMを文脈整理の支援として用いたが、抽出された `problem_context` や `solution_context` がどの程度正確であるかを体系的に評価することは今後の課題である。人手で作成した正解データとの比較や、抽出項目ごとの誤差分析を行うことで、ランキング結果への影響を確認できる。

第四に、他ドメインへの適用が必要である。本研究では、実験1として医療画像解析から製造欠陥検出への近接解決策型候補抽出、実験2として洗浄・除去系技術から半導体洗浄への異質解決策型候補抽出を扱った。今後は、材料、制御、エネルギー、バイオ、ロボティクスなど、他の分野に適用することで、課題文脈・解決手段文脈の分離に基づく候補抽出がどのような条件下で有効に働くかを検討できる。

第五に、技術導入可能性評価との接続が必要である。本研究は、専門家確認候補を抽出するスクリーニング手法であり、技術導入の最終判断を行うものではない。実際の技術導入を検討するためには、専門家評価、実験的検証、事業上の判断、コスト、規制、既存設備との適合性などを含めた追加評価が必要である。

以上の課題は残るものの、本研究は、特許文書を課題文脈と解決手段文脈に分離することで、異分野間の専門家確認候補を説明しやすく抽出する枠組みを示した。全文類似だけでは捉えにくい候補抽出理由を整理し、人間が確認すべき候補集合を提示する点に、本研究の意義がある。

第9章 参考：クロスドメイン技術候補抽出研究の図表

本章では、参考として、クロスドメイン技術候補抽出に関する研究で生成された図表を示す。この研究は、特許文書から課題文脈と解決手段文脈を分離し、異分野間における技術候補を抽出する手法を提案している。

9.1 候補タイプの定義と実験の位置づけ

図9.1に、課題文脈類似度と解決手段文脈類似度に基づく候補タイプの概念図を示す。この図では、実験1（近接解決策型）と実験2（異質解決策型）の位置づけが明確に示されている。

9.2 提案手法の処理フロー

図9.2に、提案手法全体の処理フローを示す。特許データから候補集合の抽出、著者確認評価に至るまでの一連のプロセスが可視化されている。

9.3 実験1：U-Net 候補抽出フロー

図9.3に、実験1の処理フローを示す。医療画像解析分野から製造欠陥検出分野へのU-Net関連候補抽出のプロセスが示されている。




図 9.1: 候補タイプと実験の位置づけ

提案手法の全体処理フロー




図 9.2: 提案手法の全体処理フロー

実験1フロー：U-Netを対象とした近接解決策型




図 9.3: 実験 1 フロー：U-Net を対象とした近接解決策型

9.4 実験 2：異質解決策型分析フロー

図 9.4 に、実験 2 の処理フローを示す。洗浄・除去系技術を対象とした異質解決策型候補抽出のプロセスが可視化されている。

実験2フロー：異質解決策型の補助分析



目的：技術導入可能性の証明ではなく、専門家確認候補を抽出する。

図 9.4: 実験 2 フロー：異質解決策型の補助分析

9.5 実験 1 の U-Net 候補抽出結果

実験 1 では、医療画像解析分野 (A0) から製造欠陥検出分野 (B0) への U-Net 関連候補抽出を実施した。データセットは過去・将来期間で分割され、過去の U-Net 関連特許からベースラインを構築し、将来期間における候補抽出の有効性を検証した。提案手法による候補ランキングと従来の全文類似度ベースラインを比較し、候補集合の性質の違いを分析した。

9.6 実験 2 の異質解決策型分析

実験 2 では、洗浄・除去系技術を対象とした異質解決策型分析を実施した。半導体洗浄課題に関連する複数の用途クラスタを設計し、各クラスタにおける候補抽出を行った。この分析は補助分析として位置づけ

られ、異質解決策型における候補の解釈可能性を探索的に検証した。

第 A 章 LLM 文脈抽出プロンプトの概要

本付録では、本研究で用いたLLM文脈抽出プロンプトの概要を示す。実際のプロンプトは、特許文書のTitle、Abstract、Claimsを入力し、候補ランキングに用いる文脈情報を構造化して出力することを目的とした。

A.1 入力

入力は、主に以下の特許文書情報で構成した。

- Title
- Abstract
- Claims
- 必要に応じて公開番号、ファミリーID、日付情報

A.2 抽出項目

LLMには、本文中で定義した抽出項目を、短い説明文として整理するよう指示した。主な抽出項目は以下である。

- `problem_context`: 発明が解こうとしている課題、目的、問題点
- `solution_context`: 課題に対して提示される構成、方法、処理手順
- `technical_means`: 具体的な技術手段、手法名、材料、構成要素
- `target_object`: 技術が適用される対象物
- `application_field`: 発明が用いられる応用分野や利用場面
- `effect_context`: 発明によって得られる効果や改善点

A.3 利用上の注意

LLM 出力は、候補の妥当性を最終判定するためのものではなく、特許文書を人間が確認しやすい文脈情報に整理するための中間表現として用いた。したがって、抽出結果には誤抽出や過度な一般化が含まれる可能性があり、候補の最終的な確認はLLM支援付き著者確認評価として行った。

参考文献

- [1] Argente, D., Baslandze, S., Hanley, D., and Moreira, S. Patents to Products: Product Innovation and Firm Dynamics. NBER Working Paper No. 34592, 2025. doi:10.3386/w34592.
- [2] Arts, S., Cassiman, B., and Hou, J. Technology Differentiation, Product Market Rivalry, and M&A Transactions. *Strategic Management Journal*, 46(4), 837–862, 2025. doi:10.1002/smj.3687.
- [3] Albora, G., Straccamore, M., and Zaccaria, A. Machine Learning-Based Similarity Measure to Forecast M&A from Patent Data. arXiv:2404.07179, 2024.
- [4] Bekamiri, H., Hain, D. S., and Jurowetzki, R. PatentSBERTa: A Deep NLP Based Hybrid Model for Patent Distance and Classification Using Augmented SBERT. *Technological Forecasting and Social Change*, 206, 123536, 2024. doi:10.1016/j.techfore.2024.123536.
- [5] Cong, L. W., Lu, Y., Shi, H., and Zhu, W. Automation-Induced Innovation Shift. NBER Working Paper No. 34240, 2025. doi:10.3386/w34240.
- [6] Devlin, J., Chang, M.-W., Lee, K., and Toutanova, K. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. In *Proceedings of NAACL-HLT 2019*, pp. 4171–4186, 2019. doi:10.18653/v1/N19-1423.
- [7] Giordano, V., Puccetti, G., Chiarello, F., Pavanello, T., and Fantoni, G. Unveiling the Inventive Process from Patents by Extracting Problems, Solutions and Advantages with Natural Language Processing. *Expert Systems with Applications*, 229, 120499, 2023. doi:10.1016/j.eswa.2023.120499.
- [8] Griliches, Z. Patent Statistics as Economic Indicators: A Survey. *Journal of Economic Literature*, 28(4), 1661–1707, 1990.
- [9] Ha, T. and Lee, J.-M. Examine the Effectiveness of Patent Embedding-Based Company Comparison Method. *IEEE Access*, 11, 23455–23461, 2023.

- doi:10.1109/ACCESS.2023.3251664.
- [10] Hain, D. S., Jurowetzki, R., Buchmann, T., and Wolf, P. A Text-Embedding-Based Approach to Measuring Patent-to-Patent Technological Similarity. *Technological Forecasting and Social Change*, 177, 121559, 2022. doi:10.1016/j.techfore.2022.121559.
 - [11] Hall, B. H., Jaffe, A., and Trajtenberg, M. Market Value and Patent Citations. *The RAND Journal of Economics*, 36(1), 16–38, 2005.
 - [12] Han, X., Zhu, D., Wang, X., Li, J., and Qiao, Y. Technology Opportunity Analysis: Combining SAO Networks and Link Prediction. *IEEE Transactions on Engineering Management*, 68(5), 1288–1298, 2021. doi:10.1109/TEM.2019.2939175.
 - [13] Hope, T., Chan, J., Kittur, A., and Shahaf, D. Accelerating Innovation Through Analogy Mining. In *Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 235–243, 2017. doi:10.1145/3097983.3098038.
 - [14] Jaffe, A. B., Trajtenberg, M., and Henderson, R. Geographic Localization of Knowledge Spillovers as Evidenced by Patent Citations. *The Quarterly Journal of Economics*, 108(3), 577–598, 1993. doi:10.2307/2118401.
 - [15] Jeong, C. and Kim, K. Creating Patents on the New Technology Using Analogy-Based Patent Mining. *Expert Systems with Applications*, 41(8), 3605–3614, 2014. doi:10.1016/j.eswa.2013.11.045.
 - [16] Jin, G. Z., Leccese, M., and Wagman, L. M&A and Technological Expansion. *Journal of Economics & Management Strategy*, 33(2), 338–359, 2024. doi:10.1111/jems.12551.
 - [17] Kalyani, A., Bloom, N., Carvalho, M., Hassan, T. A., Lerner, J., and Tahoun, A. The Diffusion of New Technologies. NBER Working Paper No. 28999, 2024. doi:10.3386/w28999.
 - [18] Kogan, L., Papanikolaou, D., Seru, A., and Stoffman, N. Technological Innovation, Resource Allocation, and Growth. *The Quarterly Journal of Economics*, 132(2), 665–712, 2017. doi:10.1093/qje/qjw040.

- [19] Lee, J.-S. and Hsiang, J. PatentBERT: Patent Classification with Fine-Tuning a Pre-Trained BERT Model. *World Patent Information*, 61, 101965, 2020. doi:10.1016/j.wpi.2020.101965.
- [20] Liu, Y., Ott, M., Goyal, N., Du, J., Joshi, M., Chen, D., Levy, O., Lewis, M., Zettlemoyer, L., and Stoyanov, V. RoBERTa: A Robustly Optimized BERT Pretraining Approach. arXiv:1907.11692, 2019.
- [21] Liu, Z., Feng, J., and Uden, L. From Technology Opportunities to Ideas Generation via Cross-Cutting Patent Analysis: Application of Generative Topographic Mapping and Link Prediction. *Technological Forecasting and Social Change*, 192, 122565, 2023. doi:10.1016/j.techfore.2023.122565.
- [22] Noel, M. and Schankerman, M. Strategic Patenting and Software Innovation. *The Journal of Industrial Economics*, 61(3), 481–520, 2013. doi:10.1111/joie.12024.
- [23] OECD. *OECD Patent Statistics Manual*. OECD Publishing, 2009. doi:10.1787/9789264056442-en.
- [24] Reimers, N. and Gurevych, I. Sentence-BERT: Sentence Embeddings Using Siamese BERT-Networks. In *Proceedings of EMNLP-IJCNLP 2019*, pp. 3982–3992, 2019. doi:10.18653/v1/D19-1410.
- [25] Rogers, E. M. *Diffusion of Innovations*. 5th ed., Free Press, 2003.
- [26] Ronneberger, O., Fischer, P., and Brox, T. U-Net: Convolutional Networks for Biomedical Image Segmentation. In *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015*, LNCS 9351, pp. 234–241, Springer, 2015. doi:10.1007/978-3-319-24574-4_28.
- [27] Trajtenberg, M. A Penny for Your Quotes: Patent Citations and the Value of Innovations. *The RAND Journal of Economics*, 21(1), 172–187, 1990. doi:10.2307/2555502.
- [28] Trapp, M. and Warschat, J. LLM-Based Extraction of Contradictions from Patents. arXiv:2403.14258, 2024.
- [29] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., and Polosukhin, I. Attention Is All You Need. In *Advances in Neural Information Processing Systems*, 30, 2017.

- [30] Wang, J., Zhang, Z., Feng, L., Lin, K.-Y., and Liu, P. Development of Technology Opportunity Analysis Based on Technology Landscape by Extending Technology Elements with BERT and TRIZ. *Technological Forecasting and Social Change*, 191, 122481, 2023. doi:10.1016/j.techfore.2023.122481.